

Trabalho realizado pelo grupo 6 do TP2 constituído pelos elementos: Ana Luísa Silva PG53634, Francisco Borges PG53822, João Gonçalves PG53946, Gonçalo Regadas PG53844, Rodrigo Cunha PG54199 para a Unidade Curricular de Apresentação e Visualização de Informação.

### **Momento 3 – Defesa da Solução**

#### **1. Indicar o objetivo do momento 3**

Nesta última fase do trabalho, o objetivo primordial é consolidar os esforços anteriores, culminando na apresentação de uma solução tangível e tecnicamente robusta para o problema proposto pela equipa de trabalho. A Fase 3 visa, sobretudo, a concretização do protótipo tecnológico desenvolvido, demonstrando não apenas a sua funcionalidade, mas também sua adaptabilidade e relevância. A integração coerente dos resultados obtidos ao longo das fases anteriores é fundamental. O documento final deverá representar uma síntese consistente e articulada das análises, experimentações e conclusões atingidas. O objetivo deste momento não é apenas apresentar a solução, mas também destacar a lógica subjacente à sua conceção e desenvolvimento e haver uma justificação de todo o processo incluindo dos artefactos escolhidos para a dashboard final.

#### **2. O que foi realizado nos últimos dois momentos**

No Momento 1, o grupo 6 definiu o contexto do projeto, identificou os stakeholders e o problema a ser abordado, que se concentra na análise de chamadas de emergência. Foram estabelecidos dois públicos-alvo: gestores de resposta a emergências e entidades locais/governamentais. A proposta do problema incluiu questões sobre variação temporal, tipos de ocorrências, variações geográficas e correlação entre tempo de resposta e frequência de chamadas.

No Momento 2, o grupo avançou para a fase de conceptualização da solução. Definiu o objetivo desta etapa como uma ponte entre as fases 1 e 3, servindo como transição entre a formulação inicial do problema e a visualização da análise de dados no Momento 3. Destacou a utilização de abordagens exploratória e explicativa na conceção da solução. Foram delineados tópicos específicos de análise para os gestores de resposta a emergências e entidades locais/governamentais. Foi também elaborada uma caracterização detalhada dos atributos resultantes das três camadas de processamento de dados: Bronze, Silver e Gold. A escolha de representações gráficas e esquemas de cores foi considerada, visando a compreensão intuitiva para públicos não especializados em dashboards.

#### **3. Descrição do problema**

Os serviços de emergências são uma parte fulcral de qualquer cidade ao redor do mundo, já que estes fornecem serviços para vários tipos de ocorrência como saúde, acidentes, incêndios entre outros. Os incêndios, sejam florestais ou urbanos, representam uma ameaça constante ao meio ambiente, à propriedade e à vida humana. As consequências desses incêndios podem ser devastadoras, resultando em danos materiais irreparáveis, deslocamento de comunidades e, em casos extremos, perdas humanas irreparáveis. Além dos incêndios, os acidentes de trânsito, são eventos imprevisíveis que causam lesões graves, incapacidades e até mesmo fatalidades. A necessidade de uma resposta rápida e eficaz diante dessas situações é vital para minimizar os danos e garantir a segurança dos afetados. Já as emergências médicas, desde casos isolados até crises de saúde pública, requerem atenção imediata e recursos médicos adequados. O rápido atendimento nessas situações pode ser crucial para salvar vidas e limitar os impactos na saúde da comunidade.

Face a esta realidade, é imperativo melhorar a alocação dos recursos nos serviços de emergência, uma vez que estes desempenham um papel crucial na resposta a uma variedade de situações, desde incêndios até emergências médicas. Uma gestão eficiente dos recursos pode resultar numa resposta mais rápida e eficaz, minimizando danos e protegendo vidas e propriedades.

A melhoria na alocação de recursos pode ser alcançada através da implementação de tecnologias avançadas, como sistemas de monitorização e algoritmos de previsão. Esses sistemas têm a capacidade de avaliar a gravidade de diversas situações, possibilitando uma distribuição mais precisa de recursos conforme a necessidade. A deteção precoce e análise de dados, por exemplo, em situações como incêndios florestais, pode resultar em uma intervenção mais ágil e eficaz.

Além disso, a coordenação entre diferentes serviços de emergência pode ser aprimorada, possibilitando uma resposta integrada a situações complexas. Com a partilha de informações entre os serviços de bombeiros, polícia e unidades médicas, é possível ter uma visão mais abrangente da situação e alocar recursos de forma estratégica.

Com isto em mente o grupo pretende ajudar este provedor de serviços públicos via a utilização de um dataset encontrado no website Kaggle (<https://www.kaggle.com/datasets/sachinpatil1280/911-emergency-calls/data>) com a ajuda de apresentação e visualização de Informação para facilitar a tomada de decisão.

O conjunto de dados do dataset aborda a frequência de chamadas de emergência 911 ao longo de 2015 e 2016, e os motivos mais comuns para as quais essas chamadas são efetuadas em diferentes períodos do ano. É um DataSet que fornece informações valiosas sobre as coordenadas geográficas sendo estas principalmente localizadas na Pensilvânia, motivos das chamadas, horários das ocorrências, códigos postais, municípios e outros detalhes essenciais para a análise das chamadas de emergência.

| Atributo  | Tipo de dados | Descrição                                                                  | Exemplo de dados                                                                     |
|-----------|---------------|----------------------------------------------------------------------------|--------------------------------------------------------------------------------------|
| lat       | Decimal       | Representa a latitude das coordenadas geográficas do local da ocorrência.  | "40.251106"                                                                          |
| lng       | Decimal       | Representa a longitude das coordenadas geográficas do local da ocorrência. | "-75.648445"                                                                         |
| desc      | String        | Descrição detalhada da chamada de emergência.                              | 'PENLLYN BLUE BELL PIKE & VILLAGE CIR; BRANCO; Estação 385; 10/12/2015 às 18:02:38;' |
| zip       | Integer       | Representa o código de endereço postal do local da chamada.                | "19464"                                                                              |
| title     | String        | Motivo da chamada de emergência, categorizando o tipo de ocorrência        | "EMS: LESÃO NA CABEÇA."                                                              |
| timeStamp | DateTime      | Data e hora exatas da ocorrência                                           | "10/12/2015 18:06:25."                                                               |
| twp       | String        | Município de quem fez a chamada de emergência                              | "DOR."                                                                               |
| Addr      | String        | Endereço de quem fez a chamada de emergência                               | "PENLLYN BLUE BELL PIKE E VILA CIR."                                                 |
| e         | Inteiro       | Variável fictícia com valor constante 1                                    | "1"                                                                                  |

*Tabela 1 - Colunas do dataset escolhido*

A descrição dos campos de dados é essencial para poder entender bem as informações que serão utilizadas nas análises subsequentes. O conhecimento dos detalhes, como coordenadas geográficas, motivo das chamadas e hora das ocorrências, é o primeiro passo para explorar a fundo as questões relacionadas às chamadas de emergência e desenvolver soluções práticas para aprimorar os serviços.

Este conjunto de dados é uma fonte fundamental para entender os padrões de chamadas de emergência 911. Permite-nos explorar como a frequência das chamadas varia ao longo do ano, bem como identificar os motivos mais comuns que levam as pessoas a fazer chamadas de emergência em diferentes momentos. Compreender essas informações é essencial para aprimorar os serviços de resposta a emergências e garantir uma assistência mais eficaz à comunidade.

#### 4. Descrição das Personas e Cenário

Este projeto de análise de dados sobre chamadas de emergência direciona-se a um público bastante específico, mas crucial para garantir a eficácia e eficiência dos serviços de resposta a situações críticas. São dois grupos de intervenientes fundamentais: gestores de resposta a emergências e entidades locais e governamentais.

Os gestores de resposta a emergências são fundamentais para o planejamento estratégico e alocação de recursos. Incluem chefes de departamento de bombeiros, diretores de serviços médicos de emergência e outros líderes operacionais, usam as análises para tomar decisões sobre onde posicionar equipas e veículos de emergência, bem como ajustar os turnos com base nas necessidades identificadas nas análises. Também desempenham um papel fundamental na identificação das necessidades de treino e formação das equipas de emergências. Com base nas análises das chamadas de emergência mais comuns e nas lições aprendidas em situações anteriores, eles podem organizar programas de treino específicos para melhorar as habilidades e competências das suas equipas. As entidades locais e governamentais desempenham um papel fundamental na implementação de ações práticas com base nas análises. Incluem presidentes de câmara, vereadores, departamentos de obras públicas e organismos responsáveis pela segurança pública.

As entidades locais e governamentais podem utilizar as análises para tomar decisões informadas sobre alocação de recursos, regulamentações e políticas. Por exemplo, se as análises indicarem um aumento significativo de incêndios numa área específica, as entidades podem direcionar investimentos para a aquisição de veículos e equipamento de combate a incêndios nessa região. Além disso, se as análises revelarem que as áreas rurais têm tempos de resposta mais longos à falta de estradas adequadas, essas autoridades podem usar essas informações para direcionar recursos e investir na melhoria da infraestrutura rodoviária.

Cada um destes públicos desempenha um papel específico na implementação das ações práticas decorrentes das análises dos dados de chamadas de emergência. São fundamentais para assegurar que as melhorias sejam devidamente planeadas, postas em prática e mantidas, contribuindo, assim, para um sistema de resposta a emergências mais eficaz e eficiente.

#### Personas:

|                                                                                    |
|------------------------------------------------------------------------------------|
|  |
| Ana                                                                                |
| Idade<br>45 anos                                                                   |
| Profissão<br>Professora                                                            |
| Morada<br>Pittsburgh,<br>Pensilvânia                                               |


Problema: Chamada de emergência ao 911 para um incêndio na sua casa no dia 26 às 18h. O tempo de resposta dos bombeiros foi de 20 minutos, o que a deixou preocupada e ansiosa.

Expectativa: Que os bombeiros cheguem rapidamente a sua casa para apagar o incêndio e proteger a sua família.

|                                                                                     |
|-------------------------------------------------------------------------------------|
|  |
| Carlos                                                                              |
| Idade<br>65 anos                                                                    |
| Profissão<br>Aposentado                                                             |
| Morada<br>Pittsburgh,<br>Pensilvânia                                                |

Problema: Chamada de emergência ao 911 para um acidente de trânsito com vítimas no dia 26 às 18h. O tempo de resposta dos bombeiros foi de 30 minutos, o que o deixou preocupado com a gravidade das vítimas.

Expectativa: Que os bombeiros cheguem rapidamente ao local do acidente para prestar socorro às vítimas.

|                                                                                   |
|-----------------------------------------------------------------------------------|
|  |
| Maria                                                                             |
| <b>Idade</b><br>35 anos                                                           |
| <b>Profissão</b><br>Chefe do departamento dos bombeiros                           |
| <b>Morada</b><br>Filadélfia, Pensilvânia                                          |

**Problema:** O tempo de resposta dos bombeiros a chamadas de emergência é um problema recorrente na região de Pittsburgh. A Maria, de certo modo encontra-se pressionada para encontrar soluções de forma a melhorar a eficiência dos serviços.

**Expectativa:** Que as análises dos dados de chamadas de emergência ajudem a identificar soluções para melhorar o tempo de resposta dos bombeiros.

|                                                                                   |
|-----------------------------------------------------------------------------------|
|  |
| Pedro                                                                             |
| <b>Idade</b><br>41 anos                                                           |
| <b>Profissão</b><br>Presidente da Câmara                                          |
| <b>Morada</b><br>Pittsburgh, Pensilvânia                                          |

**Problema:** O tempo de resposta dos bombeiros a chamadas de emergência é uma preocupação significativa na cidade. O Pedro é responsável por investir recursos para melhorar a eficiência dos serviços de emergência.

**Expectativa:** Utilizar análises de dados de chamadas de emergência para tomar decisões informadas sobre investimentos que melhorem o tempo de resposta dos bombeiros em Pittsburgh.

### Cenários:

Ana e o Carlos são dois cidadãos que moram em Pittsburgh, na Pensilvânia. Recentemente, ambos enfrentaram emergências que exigiram a intervenção dos bombeiros. No caso de Ana, o tempo de resposta dos bombeiros foi de 20 minutos, que fica preocupada e ansiosa devido ao incêndio na sua casa. Por outro lado, o Carlos teve de esperar 30 minutos pelos bombeiros em um acidente de trânsito, o que o deixou inquieto, especialmente em relação à gravidade das vítimas envolvidas.

A Maria, como chefe do departamento dos bombeiros em Pittsburgh, está sob pressão constante para encontrar soluções que aprimorem a eficiência dos serviços de emergência. Ela reconhece que o tempo de resposta dos bombeiros é um problema persistente na região e está confiante de que a análise de dados das chamadas de emergência pode oferecer insights valiosos para aprimorar o tempo de resposta da equipa. Ela analisa fatores como a localização das ocorrências, os horários de pico, o tipo de incidente e o tempo de resposta dos bombeiros. E, com base nessas análises de dados, a Maria começa a tomar medidas concretas como o posicionamento das equipas e veículos de emergência, bem como ajustar os turnos das equipas de emergência, pois o fato de as duas chamadas de emergência terem ocorrido à mesma hora demonstra uma maior frequência de chamadas durante esse período específico.

O presidente da câmara, o Pedro, também está ativamente envolvido. Ele reconhece a importância de investir em equipamentos e recursos para atender à crescente frequência de chamadas de emergência na área de Pittsburgh. O Pedro está disposto a alocar recursos significativos para melhorar a capacidade de resposta dos bombeiros.

Com essa abordagem baseada em análise de dados, a Maria e o Pedro estão comprometidos em tornar Pittsburgh mais segura e resiliente.

### 5. Explicar o problema de visualização presente no nosso tema

A proposta do problema apresenta questões-chave a serem abordadas na análise dos dados de chamadas de emergência. A especificação da visualização de dados também desempenha um papel fundamental na análise e na obtenção de insights. Nos seguintes pontos estão representados os problemas para cada

|                                                                     | Questões Problema                                                                                                                                                                                                                                                                         | Questões Problema                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                      |
|---------------------------------------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <b>Variação temporal</b>                                            | Como varia a frequência de chamadas de emergência ao longo dos meses, dias da semana e horas do dia?                                                                                                                                                                                      | Uma central de atendimento de emergência está a tentar compreender como é que a frequência das chamadas varia ao longo dos meses, dias da semana e horas do dia para otimizar a distribuição de recursos. No entanto, a falta de informações claras sobre os horários de pico, dias mais movimentados e sazonalidades impede a alocação eficiente de pessoal e equipamentos.                                                                                                                                                                                                                                           |
| <b>Tipos de ocorrências</b>                                         | Quais são os tipos de ocorrência mais comuns das chamadas de emergência? A categorização e análise do tipo de ocorrência das chamadas podem ajudar a priorizar áreas que precisam de maior atenção e recursos.                                                                            | Uma central de atendimento de emergência procura identificar os tipos mais comuns de ocorrências nas chamadas de emergência. A categorização e análise desses motivos podem auxiliar na priorização de áreas que necessitam de maior atenção e recursos.                                                                                                                                                                                                                                                                                                                                                               |
| <b>Variações geográficas</b>                                        | Como a frequência de chamadas de emergência de cada tipo de ocorrência varia de acordo com a localização (código postal)? Existem áreas com maior incidência de chamadas de saúde, incêndios ou acidentes? Essa análise pode ser valiosa para o posicionamento de recursos de emergência. | A central de atendimento de emergência deseja compreender como a frequência de chamadas de emergência varia de acordo com a localização (código postal). A análise dessas variações geográficas pode ser valiosa para o posicionamento estratégico de recursos de emergência e a identificação de áreas com maior incidência de chamadas de saúde, incêndios ou acidentes. A falta de informações claras sobre as áreas com maior incidência de diferentes tipos de ocorrências (como chamadas relacionadas à saúde, incêndios ou acidentes) dificulta a alocação estratégica de equipas e equipamentos de emergência. |
| <b>Comparação de tempo de resposta com a frequência de chamadas</b> | Como é que o tempo médio de resposta se correlaciona com o número de chamadas em cada código postal?                                                                                                                                                                                      | Uma agência de serviços de emergência está a tentar entender a relação entre a variação sazonal nas chamadas de emergência e o tempo médio de resposta em diferentes regiões (código postal). A agência percebe que durante certas épocas do ano, como feriados ou estações específicas, há um aumento significativo no volume de chamadas, afetando potencialmente os tempos de resposta. No entanto, a falta de insights claros sobre como essa variação sazonal afeta o tempo de resposta impede a otimização dos recursos para atender a esses padrões sazonais.                                                   |

*Tabela 2 - Problemas de visualização presente no nosso tema*

## 6. Caracterização dos dados

Esta tabela apresenta uma caracterização detalhada dos atributos resultantes das três camadas de processamento de dados: Bronze, Silver e Gold.

Os atributos aqui listados referem-se exclusivamente à camada Gold, onde o processo de transformação de dados é mais refinado. No Bronze, o dataset é carregado sem alterações; no Silver, o processo de extração, transformação e carga (ETL) é aplicado; e no Gold, são selecionadas as tabelas da camada Silver necessárias e realizadas as transformações adicionais para cumprir os requisitos predefinidos.

Esta tabela serve como um guia detalhado dos atributos resultantes do processo de refinamento dos dados na camada Gold, demonstrando a natureza, representação e estrutura dos dados para facilitar a sua visualização e análise.

| Atributo                   | Exemplo de dados | Tipo de dados | Nível de representação dos dados | Natureza dos dados | Escala de medição |
|----------------------------|------------------|---------------|----------------------------------|--------------------|-------------------|
| Zip code                   | 19464            | Integer       | Qualitativo                      | Discreto           | Nominal           |
| Latitude                   | 40.251106        | Decimal       | Quantitativo                     | Contínuo           | Ratio             |
| Longitude                  | -75.648445       | Decimal       | Quantitativo                     | Contínuo           | Ratio             |
| Data de chamada            | 2016-01-21       | Date          | Qualitativo                      | Discreto           | Interval          |
| Hora de chamada            | 16               | Integer       | Quantitativo                     | Discreto           | Ratio             |
| Tipo de ocorrência         | Incêndio         | String        | Qualitativo                      | Discreto           | Nominal           |
| Total de emergências       | 17               | Integer       | Quantitativo                     | Discreto           | Ratio             |
| Média do tempo de resposta | 00:07:20         | String        | Qualitativo                      | Contínuo           | Interval          |

*Tabela 3 - Caracterização dos dados*

## 7. Tópicos de análise a abordar

Nesta fase do projeto, os grupos principais, quer os gestores de resposta a emergências quer as entidades locais e governamentais, estão focados em análises específicas. Para isso teremos em conta os seguintes tópicos:

### **Tópicos a analisar pelos gestores de resposta a emergências**

#### 1. Variação do número de chamadas de emergência por dia da semana em cada mês:

Esta análise pode revelar padrões sazonais ou variações temporais nas chamadas de emergência, permitindo uma melhor alocação de recursos em dias ou meses com maior número de chamadas de emergência.

#### 2. Variação da frequência de chamadas de emergência por hora em cada dia da semana:

Identificar os horários de maior fluxo de chamadas ajuda na organização de turnos e distribuição das equipas de emergência, garantindo uma resposta mais eficaz nos momentos de maior necessidade.

#### 3. Tipos de ocorrência mais comuns das chamadas de emergência em cada dia da semana:

Compreender os tipos de emergências mais frequentes em cada dia da semana é crucial para um planeamento eficaz. Isso permite ajustar as estratégias operacionais, distribuir recursos adequadamente e garantir uma resposta otimizada às necessidades específicas de cada dia.

#### 4. Tipos de ocorrência mais comuns das chamadas de emergência em cada mês

Analisar os tipos de ocorrência mais comuns ao longo de cada mês oferece insights valiosos para o planeamento sazonal. Essa abordagem possibilita a adaptação das operações de resposta a emergências com base em padrões mensais, contribuindo para uma preparação mais eficiente e uma resposta mais ágil.

#### 5. Tipos de ocorrência mais comuns das chamadas de emergência ao longo do tempo

Examinar os tipos de ocorrência mais frequentes ao longo do tempo é essencial para identificar padrões e tendências significativas. Essa análise global possibilita um entendimento abrangente das chamadas de emergência, facilitando a implementação de estratégias de longo prazo, como a formação especializada e aquisição de recursos específicos.

#### 6. Tipos de ocorrência mais comuns das chamadas de emergência

Analisar os tipos mais comuns de ocorrências nas chamadas de emergência é de suma importância para a gestão eficiente dessas situações. Essa análise proporciona insights valiosos que podem orientar a tomada de decisões estratégicas, influenciando políticas de resposta, regulamentações e alocando recursos de maneira a atender eficazmente às necessidades emergenciais da comunidade.

## **Tópicos a analisar pelas entidades locais e governamentais**

### **7. Variação da frequência de chamadas de emergência por tipo de ocorrência e localização (código postal).**

Permite identificar áreas geográficas com maior número de emergências de certos tipos, ajudando na distribuição estratégica de recursos de emergência e na implementação de medidas preventivas específicas para essas regiões

### **8. Correlação entre o tempo médio de resposta e o número de chamadas em cada código postal.**

Esta métrica é crucial para avaliar a eficiência dos serviços de emergência em áreas específicas, identificando onde melhorias são necessárias para reduzir os tempos de resposta e, assim, melhorar a eficácia do serviço.

### **9. Tipos de ocorrência mais comuns das chamadas de emergência**

Analisar os tipos mais frequentes de ocorrências nas chamadas de emergência é fundamental para orientar o estabelecimento de políticas, regulamentações e a distribuição estratégica de recursos, visando atender de maneira eficaz às necessidades específicas da comunidade.

## **8. Hipóteses de representações**

Com base em cada um dos tópicos de análise de cada público-alvo, inicialmente optamos por explorar diversas representações gráficas para selecionar aquelas mais adequadas ao nosso propósito de oferecer suporte à tomada de decisão. Com o intuito de identificar as representações gráficas mais apropriadas para as diferentes áreas de análise, o grupo utilizou a categorização das temáticas baseando-se no número de atributos e na estrutura dos dados. O número de atributos pode ser dividido em quatro categorias distintas: univariate data, bivariate data, trivariate data e multivariate data.

Já a estrutura dos dados pode ser classificada em cinco tipos diferentes: linear, temporal, espacial ou geográfica, hierárquica e rede

- **Tópicos a analisar pelos gestores de resposta a emergências**

### **Variação do número de chamadas de emergência por dia da semana em cada mês**

Este categoriza-se em univariate, pois combina a variável de data. Com base nisto, pensou-se em recorrer a representações unidimensionais como Scatter plot, Line plot, Time series e Heat map. A estrutura de dados é classificada como temporal pois envolve a variação das chamadas de emergência ao longo do tempo (dias da semana em cada mês).

### **Variação da frequência de chamadas de emergência por hora em cada dia da semana**

Este categoriza-se em bivariate, pois combina as variáveis datas com a de horário. Com base nisto, pensou-se em recorrer a representações bidimensionais como Scatter plot, Line plot, Time series e Heat map. A estrutura de dados é classificada como temporal e linear pois analisa a variação por hora (linear) em diferentes dias da semana (temporal).

### **Tipos de ocorrência mais comuns das chamadas de emergência em cada dia da semana.**

Este categoriza-se em bivariate, pois combina as variáveis tipo de ocorrência com a data. Com base nisto, pensou-se em recorrer a representações bidimensionais como Scatter plot, Line plot, Time series, Heat map e Bar chart. A estrutura de dados é classificada como temporal e hierárquica pois estuda a ocorrência mais comum em diferentes dias da semana, possivelmente organizada por prioridade ou hierarquia de ocorrências.

### **Tipos de ocorrência mais comuns das chamadas de emergência em cada mês.**

Este categoriza-se em bivariate, pois combina as variáveis tipo de ocorrência com a data. Com base nisto, pensou-se em recorrer a representações bidimensionais como Scatter plot, Line plot, Time series, Heat map e Bar chart. A estrutura de dados é similar ao anterior, também é classificada como temporal e hierárquica, mas analisa a ocorrência mais comum ao longo dos meses.



### Tipos de ocorrência mais comuns das chamadas de emergência ao longo do tempo

Este categoriza-se em bivariate, pois combina as variáveis tipo de ocorrência com a data. Com base nisto, pensou-se em recorrer a representações bidimensionais como Scatter plot, Line plot, Time series, Heat map e Bar chart. A estrutura de dados é classificada como temporal e hierárquica estuda a ocorrência mais comum ao longo do tempo, possivelmente organizada por prioridade ou hierarquia de ocorrências.

- **Tópicos a analisar pelos gestores de resposta a emergências e pelas entidades locais e governamentais**

### Tipos de ocorrência mais comuns das chamadas de emergência

Este categoriza-se em univariate, pois apenas tem a variável o tipo de ocorrência. Com base nisto, pensou-se em recorrer a representações unidimensionais como Bar chart, Pie chart, Box plot, Bubble chart e Heat map. A estrutura de dados é classificada como hierárquica e unidimensional pois analisa apenas os tipos de ocorrência, provavelmente organizados por frequência ou prioridade.

- **Tópicos a analisar pelas entidades locais e governamentais**

### Variação da frequência de chamadas de emergência por tipo de ocorrência e localização (zip code)

Este categoriza-se em trivariate, pois faz a correlação entre as variáveis de total de chamadas, o tipo de ocorrência e a localização (zip code). Com base nisto, pensou-se em recorrer a representações unidimensionais como Map, Tree map, Bar chart, Box plot, Bubble chart e Heatmap. A estrutura de dados é classificada como espacial ou geográfica e tridimensional que correlaciona a frequência de chamadas por tipo de ocorrência com localizações diferentes (zip code).

### Correlação entre o tempo médio de resposta e o número de chamadas em cada zip Code

Este categoriza-se em trivariate, pois faz a correlação entre as variáveis de tempo médio, número de chamadas e de localização (zip code). Com base nisto, pensou-se em recorrer a representações unidimensionais como Map, Tree map, Bar chart, Box plot, Bubble chart e Heatmap. A estrutura de dados é classificada como espacial ou geográfica e tridimensional correlaciona o tempo médio de resposta com o número de chamadas em cada localização (zip code).

## **9. Fatores adicionais para os artefactos**

A procura por uma solução eficaz de visualização de dados é crucial para a compreensão e ação diante das informações. Considerando a importância de representar dados sobre chamadas de emergência de forma clara e identificável, a escolha criteriosa de esquemas de cores torna-se essencial.

Na visualização de dados sobre chamadas de emergência, é primordial a escolha de cores facilmente distinguíveis para representar cada tipo de ocorrência. O uso estratégico de cores, como vermelho para incêndios, o vermelho é a cor das chamas, o que é uma associação intuitiva e facilmente identificável. O vermelho é uma cor que está associada ao perigo e à urgência, o que é apropriado para representar incêndios, que são situações de risco iminente. O verde para emergências médicas, pois o verde é uma cor que está associada à saúde e ao bem estar, o que é apropriado para representar emergências hospitalares, que são situações que requerem atendimento médico imediato. E por fim o cinza para representar os acidentes. O cinza é uma cor neutra, que pode ser utilizada para representar acidentes, que são situações que podem ser causadas por diversos fatores.

Além dessas cores, também é possível utilizar outras paletas de cores para representar outras informações, como a frequência de chamadas. No caso da frequência de chamadas, é possível utilizar uma paleta de cores em tons de azul. Quanto mais escuro for o azul, maior será o número de chamadas. Essa paleta de cores é apropriada para representar a frequência de chamadas, pois o azul é uma das cores usadas na emergência, sendo uma cor que é associada à segurança e à autoridade. Por exemplo, a cor azul é utilizada na roupa dos bombeiros, que são profissionais que atuam em emergências. O vermelho também poderia ser uma boa opção para representar a frequência de chamadas, pois é uma cor que é associada à urgência e ao perigo. No entanto, o vermelho já está a ser utilizado para representar os dados dos incêndios.



Entretanto, ao considerar a apresentação dessas informações, surge a necessidade de uma plataforma acessível ao público-alvo. Embora a utilização de cores intuitivas seja essencial, a apresentação dos dados nas dashboards específicas para cada público torna-se uma alternativa atraente. Essas dashboards, reúnem informações de maneira compacta e compreensível, através de gráficos, para oferecer uma visão geral instantânea e clara dos dados.

A escolha das cores, embora crucial, não é o único fator a considerar. A facilidade de interpretação e a rápida compreensão das informações são igualmente relevantes. Assim, a capacidade de apresentar os dados de forma clara e concisa, aliada à escolha de paletes de cores coerentes e consistentes, é fundamental para transmitir eficazmente a mensagem ao público-alvo.

A equipa decidiu usar ainda uma dashboard F-shaped pois é um design eficiente e intuitivo para apresentar informações essenciais. Com uma disposição que segue o padrão da letra 'F',. Elementos como títulos claros, gráficos significativos e métricas importantes são posicionados estrategicamente ao longo do layout, permitindo uma rápida absorção de informações cruciais sem sobrecarregar visualmente o utilizador. Essa abordagem é ideal para destacar dados prioritários e facilitar a navegação e compreensão da informação de forma rápida e eficiente.

Portanto, ao criar esses artefactos de visualização de dados, a combinação entre o esquema de cores criteriosamente escolhido para representar as ocorrências e a apresentação em dashboards específicas para cada público-alvo torna-se uma estratégia poderosa. Essa abordagem procura não apenas representar as informações de forma visualmente impactante, mas também garantir a compreensão e a tomada de decisões informadas, contribuindo assim para um resultado efetivo e relevante.

## 10. **Justificação dos artefactos com fundamentação baseada na literatura**

### **Tópicos a analisar pelos gestores de resposta a emergências:**

#### **1. Variação do número de chamadas de emergência por dia da semana em cada mês:**

- **Gráfico Escolhido:** Heatmap
- **Justificação:** Optamos pelo Heatmap para visualizar a distribuição horária das chamadas em diferentes dias da semana. As cores intuitivamente indicam os horários de pico, proporcionando uma compreensão rápida e prática dos padrões diários.

#### **2. Variação da frequência de chamadas de emergência por hora em cada dia da semana:**

- **Gráfico Escolhido:** Heatmap
- **Justificação:** O Heatmap é adequado para visualizar a distribuição de chamadas por hora em diferentes dias da semana. As cores podem indicar os horários de pico de chamadas, facilitando a identificação de padrões diários.

#### **3. Tipos de ocorrência mais comuns das chamadas de emergência em cada dia da semana:**

- **Gráfico Escolhido:** Gráfico de Barras
- **Justificação:** O Gráfico de Barras foi escolhido pela sua capacidade de comparar a distribuição dos tipos de ocorrência ao longo dos dias. Cada barra representa um tipo, facilitando a identificação das prioridades diárias de resposta a emergências.

#### **4. Tipos de ocorrência mais comuns das chamadas de emergência em cada mês:**

- **Gráficos Possíveis:** Gráfico de Barras, Heatmap
- **Gráfico Escolhido:** Gráfico de Barras

- **Justificação:** Similar ao anterior, o Gráfico de Barras destaca as prioridades mensais, sendo eficaz para comparar a distribuição dos tipos de ocorrência ao longo dos meses do ano.

#### 5. Tipos de ocorrência mais comuns das chamadas de emergência ao longo do tempo:

- **Gráfico Escolhido:** Gráfico de Linhas
- **Justificação:** Optamos pelo Gráfico de Linhas para visualizar as variações nos tipos de ocorrência ao longo do tempo. Cada linha representa um tipo, permitindo observar mudanças nas frequências ao longo do tempo, identificando tendências e padrões relevantes.

### Tópicos a analisar pelos gestores de resposta a emergências e pelas entidades locais e governamentais:

#### 6. Tipos de ocorrência mais comuns das chamadas de emergência:

- **Gráfico Escolhido:** Gráfico de Barras
- **Justificação:** O Gráfico de Barras oferece uma visão global da distribuição dos tipos de ocorrência, possibilitando uma análise comparativa fácil da prevalência de cada tipo, orientando decisões estratégicas.

### Tópicos a analisar pelas entidades locais e governamentais:

#### 7. Variação da frequência de chamadas de emergência por tipo de ocorrência e localização (código postal):

- **Gráfico Escolhido:** Mapa de Calor Geográfico (Heatmap Geográfico)
- **Justificação:** O Heatmap Geográfico destaca áreas com maior incidência de diferentes tipos de ocorrências, sendo crucial para identificar padrões locais. Facilita a alocação estratégica de recursos com base na distribuição geográfica das chamadas.

#### 8. Correlação entre o tempo médio de resposta e o número de chamadas em cada código postal:

- **Gráfico Escolhido:** Heatmap
- **Justificação:** Optamos pelo Heatmap para visualizar a correlação entre número de chamadas e tempo médio de resposta em diferentes áreas (códigos postais). Destaca áreas que necessitam melhorias nos tempos de resposta, proporcionando insights valiosos para aprimorar eficiência operacional e satisfação do público.

### 11. Possíveis suportes de apresentação

No que diz respeito aos possíveis suportes de apresentação, tivemos em consideração 3 tipos de suportes possíveis passíveis de ser utilizados para ajudar na tomada de decisão do nosso público-alvo. No que diz respeito ao site, este poderia se tratar de uma plataforma versátil para apresentações, permitindo a inclusão de texto, imagens, vídeos e interações dinâmicas. Realmente se fossemos a usar um site, a principal vantagem que víamos era a capacidade de personalização, criando uma narrativa rica para transmitir informações. No entanto, esta navegação pode ser desafiadora se não for intuitiva, o que condiciona as tomadas de decisões em tempo real por parte do nosso público-alvo.

Referente agora a uma outra alternativa, esta visa em ser uma aplicação que também são consideradas ótimas para visualizações, especialmente se forem interativas, oferecendo funcionalidades específicas como cálculos, simulações ou análises de dados em tempo real. No entanto, a necessidade de instalação e a familiaridade com a interface podem representar obstáculos para o nosso público-alvo, o que uma vez mais dificulta a tomada de decisão por parte destes. Assim sendo, e não menos importante, deparemos nos com o facto de poder apresentar uma dashboard para cada persona nesta fase, de modo a possibilitar uma percepção, uma análise e uma ajuda clara para a intervenção por parte dessas personas, facilitando assim uma tomada de decisão pensada corretamente com vista

nos dados visualizados e analisados. Portanto, essas dashboards, seriam uma ferramenta visual que reúne informações de forma condensada e compreensível, combinando assim em gráficos, tabelas, Heat Maps e outros elementos visuais para oferecer uma visão geral rápida e clara dos dados a serem visualizados. De facto, a grande vantagem está na facilidade de interpretação e na rápida compreensão da visualização da informação.

Considerando a necessidade de uma apresentação intuitiva e de fácil visualização, a opção da dashboard para cada público-alvo parece ser a escolha mais adequada. A capacidade de apresen

## 12. Escolha do suporte de Apresentação

A escolha da dashboard como suporte para apresentar informações e auxiliar na tomada de decisão do público-alvo baseia-se em diversos fatores essenciais para uma comunicação eficaz e uma análise precisa da visualização.

Primeiramente, as dashboards oferecem uma síntese visual de informações complexas, permitindo compactar dados variados num formato claro e compreensível. Essa capacidade de oferecer uma visão panorâmica e rápida é fundamental para as personas que precisam de tomar decisões ágeis e informadas. Além disso, a facilidade de interpretação é uma grande vantagem das dashboards. Ao combinar gráficos, tabelas e elementos visuais, estas conseguem simplificar a compreensão, a visualização e a análise, permitindo que o público-alvo absorva rapidamente as informações relevantes. No fundo, a adaptabilidade das dashboards para diferentes personas também é um ponto positivo. Estas podem ser personalizadas para atender às necessidades específicas de cada grupo, oferecendo uma abordagem mais direcionada e centrada na persona em questão.

A escolha da dashboard supera as possíveis limitações das outras alternativas já mencionadas em cima na parte dos suportes possíveis de apresentação, como a complexidade de navegação num website ou a necessidade de instalação e familiarização com uma aplicação específica. A facilidade de acesso e a clareza na apresentação dos dados são elementos cruciais para garantir uma tomada de decisão informada e ágil por parte do público-alvo.

Em resumo, a decisão de utilizar a dashboard como suporte justifica-se pela sua capacidade de apresentar informações de forma clara, concisa e personalizada, facilitando a interpretação e permitindo uma tomada de decisão mais assertiva e direcionada para as necessidades de cada público-alvo.

## 13. Tecnologias utilizadas no desenvolvimento do Projeto (M2 + M3)

As plataformas usadas para visualização de dados desempenham um papel crucial na análise e interpretação de conjuntos de dados simples e até mesmo complexos como é o nosso caso. Neste projeto, foi adotada uma abordagem que integra várias ferramentas para gestão, processamento e visualização de dados.

Inicialmente, o Talend foi utilizado para assegurar a qualidade dos dados. Esta ferramenta desempenha um papel essencial na validação, limpeza e enriquecimento dos dados antes mesmo de entrarem no pipeline principal. Com o Talend, foram aplicadas regras de qualidade e verificação de integridade, garantindo assim a fiabilidade e consistência dos dados desde o início do processo.

Em seguida, o Docker foi o ambiente escolhido para executar diferentes serviços, incluindo o HDFS (Sistema de Ficheiros Distribuídos Hadoop), o Hive Metastore, o Jupyter e o Trino (anteriormente conhecido como PrestoSQL). Esta escolha proporcionou um ambiente consistente e isolado para executar e interagir com estas ferramentas, facilitando a configuração e gestão. O Jupyter desempenhou um papel central, permitindo criar um ambiente de desenvolvimento interativo em Python.

Com isto, foi possível programar e executar códigos para manipular os dados. O processo começou com a criação de uma pasta chamada "AVI". Nesta pasta, os conjuntos de dados foram armazenados na camada "bronze", sem qualquer modificação em relação à sua forma original proveniente da fonte.

Na camada "silver", foram aplicadas transformações aos dados, os quais foram guardados num local específico para posterior utilização na criação de tabelas. Estas tabelas foram então armazenadas na base de dados. Posteriormente, para criar a tabela na camada "gold", foram seleccionadas as tabelas da camada "silver" necessárias e aplicadas as transformações adicionais necessárias para cumprir os requisitos predefinidos.

Esta tabela resultante foi armazenada na base de dados, juntamente com o manifesto correspondente. Este manifesto é crucial para o processo de visualização, pois é utilizado no Tableau para criar painéis de informação. Efetivamente, o Tableau foi a plataforma escolhida para a visualização eficaz dos dados, utilizando o manifesto para orientar a criação dos painéis. Estes painéis foram capazes de suportar as decisões das personas, fornecendo informações claras e relevantes extraídas dos dados processados, facilitando assim a compreensão e as tomadas de decisões, sendo estas realizadas de forma mais clarividente e assertivas. Assim sendo, a utilização integrada destas plataformas e ferramentas - Talend para garantia da qualidade dos dados, Docker, HDFS, Hive Metastore, Jupyter, Trino (PrestoSQL) e Tableau - permitiu a manipulação, processamento e visualização eficiente dos dados, desde a camada de entrada até à criação de painéis informativos e de fácil compreensão. Esta seleção cuidadosa de tecnologias e a abordagem integrada permitiram não só a manipulação eficiente dos dados em diferentes camadas, mas também a criação de um artefacto de visualização intuitivo de análise e de certa forma “poderoso” que teve em conta as necessidades específicas do projeto, fornecendo insights valiosos para as pessoas envolvidas, permitindo ajudar as personas a tomar as melhores decisões face aos desafios colocados através da visualização da informação presentes nas dashboards.

A escolha destas tecnologias específicas resultou de uma cuidadosa avaliação das necessidades do projeto tendo sempre em conta o foco final da visualização da informação para as personas que iriam interagir com estas. Deste modo, optámos por estas tecnologias devido à sua robustez e à capacidade de cumprir os requisitos exigentes de validação, processamento e visualização de dados.

Em comparação com outras opções, cada ferramenta oferecia um conjunto único de funcionalidades que se integravam perfeitamente nas etapas do nosso fluxo de trabalho. A nossa abordagem com estas tecnologias foi bastante dinâmica.

Concluindo tudo o que foi referido em cima, e acabando por de alguma forma resumir o mesmo, o verdadeiro teste de eficácia destas tecnologias foi percebido ao conhecer e utilizar o artefacto de visualização resultante. Através dele, pudemos comprovar como as escolhas feitas anteriormente foram fundamentais para fornecer informações precisas, de fácil compreensão e altamente relevantes para as tomadas de decisão de cada persona envolvida.

## 14. Apresentação das Dashboards

A apresentação de dashboards representa uma abordagem essencial e altamente eficaz na visualização e análise de dados, especialmente para a gestão de resposta a emergências. Essas interfaces visuais não apenas condensam informações cruciais, mas as apresentam de maneira acessível e compreensível por meio de gráficos e formatos intuitivos. Proporcionando uma visão detalhada e clara dos padrões de chamadas de emergência, as dashboards oferecem uma perspectiva abrangente das tendências e comportamentos subjacentes aos dados.

A capacidade de criar dashboards personalizadas para diferentes públicos-alvo é fundamental, pois permite apresentar os dados de forma específica e relevante para cada grupo. Isso não apenas facilita a compreensão, mas também agiliza o processo de tomada de decisão informada. Identificar prioridades e tendências significativas através dessas representações visuais é crucial para orientar ações estratégicas eficazes e fundamentadas, possibilitando respostas mais ágeis e assertivas diante de emergências.

A primeira visualização que temos é uma dashboard completa, repleta de gráficos, dados e métricas cruciais para os gestores de resposta de emergência.

É como um painel informativo que oferece uma visão ampla e detalhada de todas as informações relevantes. Esta dashboard foi especificamente desenhada para atender às necessidades dos gestores de resposta de emergência, tendo em mente a persona que criamos anteriormente, a Maria.




Figura 1 - Dashboard geral para o gestor de resposta de emergência

A dashboard de análise de chamadas de emergência mostra um resumo das chamadas recebidas por um serviço de emergência. A dashboard possui os cinco artefactos únicos para o público-alvo e o artefacto que está presente em ambos os públicos-alvos que listamos anteriormente, sendo estes:

### 1. Variação do número de chamadas de emergência por dia da semana em cada mês:

- Identificação de tendências de subida ou descida em determinados dias da semana ao longo dos meses.
- Possibilidade de encontrar padrões de comportamento consoante o mês ou estação do ano.
- Exemplo prático: Observar um aumento acentuado às segundas-feiras durante o verão devido a acidentes de trânsito após fins de semana prolongados, enquanto nos meses de inverno, as sextas-feiras registam um aumento nas chamadas devido a problemas relacionados com o clima, como acidentes em estradas escorregadias.

### 2. Variação da frequência de chamadas de emergência por hora em cada dia da semana:

- Descoberta dos horários de pico de chamadas em dias específicos da semana.
- Identificação de padrões de comportamento de acordo com o dia da semana.
- Exemplo prático: Identificação de picos de chamadas às 8h e 18h em dias úteis devido a acidentes de trânsito durante os horários de pico, e picos noturnos nos fins de semana devido a emergências médicas em locais de entretenimento.

### 3. Tipos de ocorrência mais comuns das chamadas de emergência em cada dia da semana:

- Reconhecimento dos tipos de incidentes mais frequentes em dias específicos.
- Possibilidade de ajustar recursos de emergência com base nos tipos de ocorrência mais comuns em dias específicos da semana.

- Exemplo prático: Ocorrências médicas tendem a ser mais comuns nas noites de sexta e sábado devido a atividades sociais intensas, enquanto chamadas relacionadas a incêndios domésticos aumentam aos domingos, frequentemente associados a preparações para a semana.

#### 4. Tipos de ocorrência mais comuns das chamadas de emergência em cada mês:

- Observação de variações nos tipos de incidentes ao longo do ano.
- Identificação de tendências sazonais ou eventos específicos relacionados a determinados tipos de ocorrência.
- Exemplo prático: Durante os meses de dezembro e janeiro, aumentam as chamadas relacionadas a queimaduras e incêndios devido a decorações natalícias. Em julho e agosto, os acidentes por afogamento aumentam devido a atividades em áreas aquáticas.

#### 5. Tipos de ocorrência mais comuns das chamadas de emergência ao longo do tempo:

- Análise da evolução dos tipos de incidentes ao longo dos anos.
- Identificação de mudanças significativas na natureza das ocorrências ao longo do tempo.
- Exemplo prático: Observação de uma redução progressiva de chamadas relacionadas a incêndios domésticos ao longo dos anos devido a campanhas educativas e instalação de detetores de fumo obrigatórios.

#### 6. Tipos de ocorrência mais comuns das chamadas de emergência:

- Compreensão dos tipos de incidentes predominantes de forma geral.
- Exemplo prático: Acidentes de trânsito podem representar a maior parte das chamadas de emergência, levando à necessidade de enfatizar programas de prevenção e segurança rodoviária. Auxílio na alocação de recursos e treino com base nas ocorrências mais comuns.

Inicialmente é possível notar que quem está a usar a dashboard é a Maria que é a persona criada pelo grupo, para representar o público-alvo gestor de resposta de emergência.

De notar que para além dos diferentes tipos de gráficos é ainda possível fazer a filtragem do tipo de chamada de emergência (sendo estes os incêndios, saúde e acidentes). É igualmente ainda possível filtrar pela data que a persona possa desejar ver, para poder obter dados mais pormenorizados nas datas que a persona escolheu. Na dashboard é possível ainda ver um gradiente do número de chamadas, sendo o azul mais claro uma menor frequência de chamadas de emergência e o azul mais escuro uma maior concentração de chamadas de emergência. É importante de destacar que ao passar o rato em cima de uma célula de um gráfico, é possível obter dados mais pormenorizados, sendo estes do tipo de emergência, assim como data e a quantidade. Por fim é possível ainda ver cada gráfico em específico apenas por escolher um dos gráficos especificados no retângulo com ícones de gráficos.

Após a persona clicar no primeiro gráfico pormenorizado que é referente aos artefactos tipos de ocorrência mais comuns das chamadas de emergência em cada mês e tipos de ocorrência mais comuns das chamadas de emergência em cada dia da semana, é apresentada a seguinte dashboard




Figura 2 - Dashboard pormenorizada de tipos de ocorrência mais comuns das chamadas de emergência em cada mês e tipos de ocorrência mais comuns das chamadas de emergência em cada dia da semana

Este dashboard mais pormenorizada é possível notar primeiramente que no retângulo para poder ver as dashboards mais ao pormenor a que selecionamos ganhou agora cor, para representar a dashboard que a persona se encontra. Ainda relativo a diferenças entre a dashboard geral e a que estamos a analisar agora apenas temos dois filtros, o filtro para escolher o tipo de emergência e a escolha da data, se passarmos o rato por cima de uma célula do gráfico é também possível obter também informação pormenorizada sobre a mesma.

Ao seleccionarmos por exemplo o tipo de emergência da saúde e seleccionarmos ainda os meses entre fevereiro e agosto, podemos notar as diferenças claras nos gráficos:



Figura 3 - Uso de filtros para a dashboard anterior



Se passarmos agora para o retângulo do meio que representa os artefactos variação do número de chamadas de emergência por dia da semana em cada mês e variação da frequência de chamadas de emergência por hora em cada dia da semana que são representados por heat maps, está será a dashboard apresentada:



Figura 4 - Dashboard pormenorizada sobre variação do número de chamadas de emergência por dia da semana em cada mês e variação da frequência de chamadas de emergência por hora em cada dia da semana

Em termos de diferenças podemos notar novamente no retângulo que mostra à pessoa em que gráfico pormenorizado se encontra, agora está o gráfico relativo ao heatmap com cor e o que estávamos anteriormente perdeu a cor. Por fim podemos notar que foi adicionado novamente o gradiente que mostra a quantidade de chamadas pela intensidade de azul.

Por fim temos a dashboard referente aos tipos de ocorrência mais comuns das chamadas de emergência ao longo do tempo, representa o artefacto tipos de ocorrência mais comuns das chamadas de emergência ao longo do tempo está será a dashboard apresentada:





Figura 5 - Dashboard pormenorizada de Tipos de ocorrência mais comuns das chamadas de emergência ao longo do tempo

Podemos notar novamente a mudança de cor no retângulo que apresenta a dashboard pormenorizada. Temos apenas os filtros de data e tipos de emergência, para a persona poder filtra na dashboard.

Após a análise de uma das dashboards específicas para um dos públicos-alvos, podemos mudar de persona, clicando na seta que é apresentada no cabeçalho. Ao clicar é aberto um drop down menu que contém a outra persona, como podes verificar na seguinte imagem:



*Figura 6 - Cabeçalho de todas as dashboards*

Já a dashboard relativa às entidades locais e governamentais, que é correspondente à persona chamada Pedro criada pelo grupo de trabalho. Esta dashboard aborda os artefactos específicos deste público-alvo e o artefacto que está presente em ambas as representações:

**1. Variação da frequência de chamadas de emergência por tipo de ocorrência e localização (código postal):**

- **Identificação de Picos e Tendências:** Observar picos de chamadas em tipos específicos de ocorrências ou em áreas específicas pode indicar a necessidade de recursos adicionais nesses locais ou situações.
- **Análise de Distribuição Geográfica:** Compreender se certos tipos de ocorrências são mais comuns em determinadas regiões pode ajudar na alocação estratégica de recursos de emergência.
- **Caso Prático:** Ao analisar os dados, descobres que num determinado código postal, as chamadas relacionadas a incêndios domésticos são significativamente mais frequentes em comparação com outras áreas. Isto pode indicar a necessidade de campanhas de sensibilização sobre segurança contra incêndios ou até mesmo a implementação de programas de inspeção e educação nessa região específica para reduzir o número de ocorrências.

**2. Correlação entre o tempo médio de resposta e o número de chamadas em cada código postal:**

- **Eficiência de Resposta:** Identificar se áreas com um alto volume de chamadas têm tempos médios de resposta mais longos pode indicar a necessidade de otimização ou realocação de recursos para melhorar a resposta.
- **Análise Temporal:** Observar se o tempo médio de resposta varia ao longo do tempo pode ajudar a identificar melhorias ou problemas sazonais ou periódicos.
- **Caso Prático:** Percebes que num código postal com elevado volume de chamadas, o tempo médio de resposta é consistentemente maior do que noutras áreas. Ao investigar mais a fundo, descobre-se que a rede de estradas naquela área é deficiente, atrasando as equipas de resposta. Isto pode levar a uma recomendação para otimizar rotas ou até mesmo estabelecer um posto de resposta mais próximo para reduzir o tempo de chegada.

**3. Tipos de ocorrência mais comuns das chamadas de emergência:**

- **Priorização de Recursos:** Compreender os tipos de ocorrências mais frequentes ajuda a priorizar treino e recursos para lidar com esses incidentes específicos.
- **Planeamento de Prevenção:** Identificar tendências nos tipos de ocorrências pode ser útil para desenvolver programas de prevenção direcionados.

- Caso Prático: Análises revelam um aumento significativo no número de chamadas relacionadas a emergências médicas num determinado período do ano numa área específica. Ao investigar mais a fundo, descobre-se que durante esse período, uma grande concentração de eventos desportivos ocorre naquela região, levando a um aumento de lesões desportivas e emergências médicas relacionadas. Isto pode incentivar a implementação de serviços médicos temporários ou intensificados nessas áreas durante eventos semelhantes para lidar com a procura adicional.

Sendo assim, está é a dashboard geral para o Pedro:




Figura 7 - Dashboard geral para entidades locais e governamentais

Podemos verificar que esta é a dashboard que contém todos os gráficos que acabamos por escolher. É possível notar que temos novamente o filtro para a escolha de tipos de ocorrências e temos um novo filtro que é para a escolha do código postal, este é um filtro muito importante para o público-alvo em questão. Temos também o gradiente para facilitar a compreensão do número de chamadas. E novamente, quando passamos o rato por cima de uma célula de um dos gráficos, é mostrado informação mais pormenorizada sobre essa célula, podendo obter um pouco mais de informações nesta dashboard geral para a persona criada para as entidades locais e governamentais.

Na transição para a primeira das visualizações mais detalhadas, que oferece uma visão inicial e detalhada dos dados. Com esta dashboard temos uma maior informação sobre o número de chamadas por cada código postal, para podermos ter uma perceção de quais são as zonas com mais chamadas de emergência, podendo à primeira vista notar a grande discrepância entre os vários códigos postais:




Figura 8 – Dashboard pormenorizada de tipos de ocorrência mais comuns das chamadas de emergência

Aqui é representado o artefacto tipos de ocorrência mais comuns das chamadas de emergência, podemos ver o gráfico de barras que foi a escolha final mais pormenorizado, nesta dashboard temos dois filtros, um que é para escolher o tipo de ocorrência e outro para escolher os códigos postais que queremos verificar. Ao passar com o rato por cima de uma barra do gráfico é possível obter informações mais específicas, para ajudar a persona a obter mais informações.

Avançando para o segundo gráfico detalhado na tabela, esta seção oferece uma análise minuciosa e aprofundada do tempo médio de resposta em relação aos códigos postais e à quantidade significativa de emergências atendidas. Aqui, é apresentada uma representação visual detalhada do artefacto de correlação entre o tempo médio de resposta e o volume considerável de chamadas em cada código postal específico. A próxima imagem na dashboard proporciona uma visão ampliada e detalhada dessa análise, oferecendo insights valiosos sobre como o tempo de resposta se relaciona com o número expressivo de chamadas em diferentes códigos postais. Essa representação visual elaborada destaca padrões relevantes, discrepâncias marcantes e possíveis insights cruciais relacionados à eficiência dos serviços de emergência em várias regiões:





Figura 9 - Dashboard pormenorizada de correlação entre o tempo médio de resposta e o número de chamadas em cada código postal

De salientar que também possui o gradiente que mostra o total de chamadas na tabela, onde uma maior intensidade representa um maior número de chamadas.

Na transição para a terceira dashboard mais detalhada, somos imediatamente introduzidos a uma nova visualização da interface, oferecendo uma perspetiva aprofundada e novos insights sobre os dados em análise. Esta tela da dashboard expande ainda mais a compreensão dos padrões, correlações e métricas relevantes para a gestão de emergências. Mantendo a clareza e organização das informações, essa dashboard proporciona elementos específicos e cruciais para análise e tomada de decisão, agregando valor ao processo de gestão e análise dos dados voltados para emergências:



*Figura 10 – Dashboard pormenorizada de variação da frequência de chamadas de emergência por tipo de ocorrência e localização (código postal)*

Esta dashboard representa o artefacto variação da frequência de chamadas de emergência por tipo de ocorrência e localização (código postal), a representação escolhida foi o mapa de calor geográfico (Heatmap Geográfico). Em relação a filtros temos na mesma a possibilidade de escolha do tipo de chamada, temos ainda o filtro para seleccionar o código postal, sabendo que inicialmente vêm todos os códigos postais seleccionados. É apresentado ainda também o gradiente que neste caso significa um azul mais intenso um maior número de chamadas e uma cor mais esbranquiçada é um menor número de chamadas feitas. E ao passar o rato por cima de uma célula do mapa, podemos obter informações mais detalhas, como vamos poder ver no printscreen a seguir.

De seguida podemos ver o mesmo gráfico, mas com o uso dos filtros, que no caso vamos destacar os fogos que existe registo nos diferentes códigos postais e com o rato em cima de uma das células para obter mais informação, que no caso podemos ver que estamos a destacar o código postal 19438 onde já houve um total de 237 fogos registados.



Figura 11 - Aplicação de filtros á dashboard anterior

Com o uso dos filtros e das dashboards mais pormenorizadas é possível ajudar a pessoa a tomar melhores decisões mais eficientes e eficazes.

Passando para a última dashboard pormenorizada, do público-alvo de entidades locais e governamentais que é representado pela pessoa criada, chamada Pedro.




Figura 12 - Dashboard pormenorizada de tipos de ocorrência mais comuns das chamadas de emergência

Nesta dashboard é apresentado um tree map e são apresentados três filtros, sendo o primeiro o filtro o de tipo de emergência, de seguida o filtro da data e por fim o filtro do código postal, onde inicialmente estão selecionados todos os códigos postais. Esta dashboard permite ter uma melhor perceção de quais são os códigos postais onde há mais tipos de emergências e a quantidade.

## 15. Avaliar a prontidão

Atingimos um marco significativo no desenvolvimento da nossa solução para a unidade curricular de Apresentação e Visualização de Informação, alcançando o Technology Readiness Level (TRL) 4, o que representa um avanço notável no contexto universitário. A nossa solução, concebida e refinada ao longo de um processo intensivo

de pesquisa e desenvolvimento, visa proporcionar uma abordagem inovadora para a análise de dados de chamadas de emergência.

No âmbito da nossa proposta, desenvolvemos uma plataforma interativa que permite a visualização e interpretação intuitivas de dados críticos relacionados às chamadas de emergência. Através da implementação de gráficos dinâmicos e ferramentas analíticas, procuramos fornecer às entidades responsáveis e gestores de resposta a emergências uma compreensão aprofundada dos padrões de ocorrências, tempos de resposta e distribuição geográfica. Durante o decorrer da unidade curricular, dedicamo-nos à elaboração e teste de protótipos, refinando continuamente a interface e as funcionalidades com base nos feedbacks e nas necessidades identificadas. Este marco não apenas valida a robustez técnica da nossa solução, mas também destaca a sua potencialidade no mundo real. A plataforma, mesmo sendo cariz académico, demonstrou capacidade para lidar com conjuntos de dados complexos, fornecendo insights valiosos para decisões operacionais e estratégicas em situações de emergência.

O TRL 4 marca a transição da teoria para uma aplicação prática, indicando não apenas a robustez técnica da nossa solução, mas também a sua utilidade potencial no mundo real. A plataforma interativa desenvolvida apresenta-se como uma ferramenta promissora para uma melhor gestão e melhorar a eficiência na resposta a emergências, destacando-se pela sua adaptabilidade e capacidade de fornecer informações cruciais de maneira acessível.

Ao alcançar o TRL 4, reforçamos não apenas a validação técnica da nossa solução, mas também a nossa dedicação em moldar uma ferramenta que possa verdadeiramente fazer a diferença na gestão de situações críticas. Este marco fortalece a base para futuras iterações e colaborações, posicionando a nossa solução como uma potencial contribuição significativa para a gestão de emergências. Assim sendo, o TRL em que a nossa solução se enquadra é de facto o 4.

## 16. Performance Indicators

Na análise das chamadas de emergência, os Performance Indicators (PIs) tornam-se instrumentos cruciais para uma avaliação abrangente. Ao oferecer uma visão holística do panorama, essas métricas possibilitam uma compreensão profunda das variações no volume de chamadas ao longo do tempo, identificando padrões essenciais. A aplicação de PIs proporciona uma perspectiva consolidada do desempenho geral, fundamentando estratégias eficazes de resposta a emergências. Dessa forma, os indicadores de desempenho desempenham um papel fundamental na otimização contínua dos protocolos de atendimento, direcionando recursos de maneira eficiente.

### Performance Indicators (PIs) para uma Visão Geral:

#### 1. Taxa de Variação Geral de Chamadas de Emergência

- **Fórmula:**  $((\text{Número total de chamadas neste período} - \text{Número total de chamadas no período anterior}) / \text{Número total de chamadas no período anterior}) * 100$
- **Objetivo:** Identificar alterações significativas no volume total de chamadas de emergência ao longo do tempo.

#### 2. Frequência Média Geral de Chamadas de Emergência por Hora

- **Fórmula:**  $(\text{Número total de chamadas} / \text{Número total de horas})$
- **Objetivo:** Determinar a média geral de chamadas por hora para otimizar a alocação de recursos.

#### 3. Percentagem Geral de Tipos de Ocorrência

- **Fórmula:**  $(\text{Número total de chamadas de um tipo específico} / \text{Número total de chamadas}) * 100$

- **Objetivo:** Obter uma visão geral da distribuição de tipos de ocorrência em todas as chamadas de emergência.

#### 4. Variação Geral de Chamadas por Tipo ao Longo do Tempo

- **Fórmula:**  $((\text{Número total de chamadas de um tipo específico} - \text{Número total de chamadas desse tipo no período anterior}) / \text{Número total de chamadas desse tipo no período anterior}) * 100$
- **Objetivo:** Identificar mudanças significativas na frequência de chamadas por tipo ao longo do tempo.

#### 5. Percentagem Geral de Tipos de Ocorrência por Área Geográfica

- **Fórmula:**  $(\text{Número total de chamadas de um tipo específico em uma área geográfica} / \text{Número total de chamadas na área geográfica}) * 100$
- **Objetivo:** Identificar áreas com maior incidência de tipos específicos de ocorrências.

### 17. Key Performance Indicators

Os Key Performance Indicators (KPIs) representam uma camada adicional de análise que visa aprofundar a compreensão do desempenho operacional no contexto das chamadas de emergência. Estes indicadores específicos são projetados para atender às necessidades distintas dos gestores de resposta a emergências e entidades locais e governamentais. Os KPIs oferecem insights detalhados sobre aspectos críticos, como variações semanais, frequência média, distribuição de tipos de ocorrências e correlações geográficas, possibilitando uma tomada de decisão mais informada e ágil. Ao integrar KPIs na análise, os responsáveis pela gestão de emergências podem otimizar estratégias, melhorar a eficiência operacional e promover uma resposta mais adaptável e eficaz em situações de crise.

#### KPIs para os Gestores de Resposta a Emergências:

##### 1. Taxa de Variação Semanal de Chamadas de Emergência:

- **Fórmula:**  $((\text{Número de chamadas desta semana} - \text{Número de chamadas da semana passada}) / \text{Número de chamadas da semana passada}) * 100$
- **Objetivo:** Identificar alterações significativas nas chamadas de emergência semanalmente.

##### 2. Frequência Média de Chamadas de Emergência por Hora:

- **Fórmula:**  $(\text{Número total de chamadas} / \text{Número total de horas})$
- **Objetivo:** Determinar os horários de maior fluxo de chamadas e otimizar a alocação de recursos.

##### 3. Percentagem de Tipos de Ocorrência por Dia da Semana:

- **Fórmula:**  $(\text{Número de chamadas de um tipo específico} / \text{Número total de chamadas no dia da semana}) * 100$
- **Objetivo:** Identificar padrões específicos de tipos de ocorrência em cada dia da semana.

##### 4. Percentagem de Tipos de Ocorrência por Mês:

- **Fórmula:**  $(\text{Número de chamadas de um tipo específico} / \text{Número total de chamadas no mês}) * 100$
- **Objetivo:** Adaptar estratégias operacionais com base em padrões mensais identificados.



#### 5. Percentagem de Tipos de Ocorrência ao Longo do Tempo:

- Fórmula:  $(\text{Número de chamadas de um tipo específico} / \text{Número total de chamadas ao longo do tempo}) * 100$
- Objetivo: Identificar tendências e ajustar estratégias de longo prazo.

#### KPIs para Entidades Locais e Governamentais:

#### 6. Taxa de Variação de Chamadas por Tipo e Localização (Código Postal):

- Fórmula:  $((\text{Número de chamadas deste código postal e tipo} - \text{Número de chamadas do código postal e tipo na semana passada}) / \text{Número de chamadas do código postal e tipo na semana passada}) * 100$
- Objetivo: Identificar mudanças significativas nas chamadas por tipo e localização.

#### 7. Correlação entre Tempo Médio de Resposta e Número de Chamadas por Código Postal:

- Fórmula: Correlação estatística entre o tempo médio de resposta e o número de chamadas em cada código postal.
- Objetivo: Avaliar se há uma relação entre o tempo médio de resposta e o número de chamadas em cada área.

#### 8. Percentagem de Tipos de Ocorrência por Área Geográfica:

- Fórmula:  $(\text{Número de chamadas de um tipo específico em uma área geográfica} / \text{Número total de chamadas na área geográfica}) * 100$
- Objetivo: Identificar áreas com maior incidência de tipos específicos de ocorrências.

#### 18. Justificação do planeamento do esforço do Momento 2 até ao final do Momento 3 concluído com êxito

Neste momento final 3, damos por concluído a fase de visualização dos gráficos que tínhamos iniciado no momento 2 para a apresentação final. O grupo esforçou-se por aprimorar os gráficos existentes, com o intuito de oferecer a melhor solução possível para facilitar a tomada de decisões precisas, especialmente para públicos menos familiarizados na área, e de facto conseguiu.

Durante esta etapa, criámos gráficos específicos para diferentes públicos-alvo, tornando as Dashboards mais acessíveis e sem dúvida bastante interativas face às personas que as possam visualizar e por fim utilizar. Estamos cientes de que realizamos todos os ajustes e melhorias para este momento final 3 ao longo deste tempo de execução. Deste modo, realizamos os ajustes que pretendíamos e que tínhamos proposto na íntegra face às visualizações já apresentadas no momento 2.

Estas mudanças planeadas do momento 2 para o 3, tiveram como objetivo aprimorar ainda mais a clareza e a intuição das informações, visando facilitar decisões assertivas. Tendo em conta o feedback recebido na avaliação anterior, modificamos com êxito o uso frequente de gráficos de barras que se encontrava em larga escala e, como é visível nas dashboards apresentadas neste momento final, visualizamos uma diversidade de gráficos para as personas que tínhamos estipulado de forma a tornar as decisões cada vez mais corretas e assertivas por parte das personas face aos desafios que estas possam vir a enfrentar. Além disto, concluímos também com êxito a forma que poderíamos aplicar filtros para garantir a máxima eficiência na interação, organizando as representações em cada dashboard. Assim sendo, as dashboards foram criadas consoante as tais melhorias que nós nos tínhamos proposto a realizar, apresentado assim bastante interatividade, persuasividade, e como esperado, dashboards sem muito “ruído” e de fácil interpretação face à clareza da visualização que estas contêm.

## 19. Conclusão do trabalho

Ao longo deste projeto, foi possível desenvolver e defender uma solução inovadora para o problema proposto, utilizando uma abordagem tecnologicamente viável. A experimentação e implementação de tecnologia foram fundamentais para promover a competência tecnológica e a consciência metodológica de nós enquanto estudantes na parte de análise e visualização de informações em sistemas de informação. A análise da frequência das chamadas de emergência para o número 911 ao longo do ano revela padrões significativos nas necessidades de resposta a diferentes incidentes em momentos específicos. A compreensão das razões comuns por trás dessas chamadas em diferentes épocas do ano é fundamental para aprimorar a preparação e a alocação de recursos de emergência. Ao longo deste estudo, foi evidente que certos tipos de incidentes emergenciais predominam em períodos específicos. Estes insights têm implicações significativas na melhoria dos serviços de emergência. O desenvolvimento de estratégias sazonais, como a implementação de serviços médicos temporários em eventos de grande escala, ou campanhas de conscientização sobre prevenção de incêndios em determinadas épocas do ano e áreas específicas, pode ser vital para atender às necessidades da comunidade de forma mais eficiente.

De facto, a compreensão dos padrões temporais das chamadas de emergência permite uma resposta mais direcionada e eficaz, garantindo uma melhor preparação para lidar com os desafios emergenciais em diferentes momentos do ano, aprimorando, assim, a segurança e o suporte prestado à população.

A avaliação abrangeu a prontidão tecnológica do protótipo, ancorada nos níveis de prontidão tecnológica, bem como um embasamento bibliográfico sólido que contextualizou tanto o problema quanto a solução proposta. A coerência do documento final como um conjunto dos três momentos de avaliação refletiu o processo contínuo de refinamento e aprimoramento ao longo do projeto. Destaca-se a eficácia da apresentação oral pública, que demonstrou de forma clara e convincente o desenvolvimento do projeto e as respectivas dashboards. Este projeto não apenas ofereceu uma resposta ao desafio proposto, mas também proporcionou um ambiente de aprendizagem significativo, fortalecendo a competência tecnológica e a compreensão metodológica neste campo específico.

Concluindo, ao longo deste projeto, não só alcançamos o desenvolvimento completo da solução proposta, como também a criação bem-sucedida das dashboards personalizadas para cada persona. Estas ferramentas (dashboards) foram cuidadosamente concebidas para fornecer às diferentes personas as informações necessárias, permitindo a tomada de decisões estratégicas com base nas visualizações apresentadas. Este aspeto fundamental do projeto não só demonstrou a capacidade de desenvolver soluções tecnológicas, mas também a habilidade de adaptar e disponibilizar informações relevantes para públicos específicos, reforçando a eficácia e utilidade do sistema desenvolvido.

## 20. Referências: Estilo APA

Ao longo da realização deste projeto, compilamos informações de fontes fiáveis que fundamentam as conclusões apresentadas ao longo deste relatório. As referências destacam a diversidade e profundidade das fontes utilizadas, fortalecendo a credibilidade deste trabalho e servindo como base sólida para as análises realizadas. Estas fontes advêm de artigos e também de algumas Teses, como prezado pelo Excelentíssimo Docente Ricardo Machado:

[1] Dos, w., da, s., & pe, r. (2022). *Universidade federal de pernambuco centro de artes e comunicação departamento de ciência da informação curso de gestão da informação visualização de dados: análise dos procedimentos para proporcionar visualizações de dados para agências de fomento à ciência e tecnologia*. <https://repositorio.ufpe.br/bitstream/123456789/47494/4/TCC%20William%20dos%20Santos%20da%20Silva.pdf>

[2] Bera, P. (2016). How colors in business dashboards affect users' decision making. *Communications of the ACM*, 59(4), 50–57. <https://doi.org/10.1145/2818993>

[3] Babich, N. (2017, April 4). F-Shaped Pattern for Reading Content. Medium; UX Planet. <https://uxplanet.org/fshaped-pattern-for-reading-content-80af79cd3394>

[4] Midway, S. R. (2020). Principles of Effective Data Visualization. *Patterns*, 1(9), 100141. sciencedirect. <https://doi.org/10.1016/j.patter.2020.100141>

[5] Wing, W., & Chan, Y. (2006). A Survey on Multivariate Data Visualization. <https://people.stat.sc.edu/hansont/stat730/multivis-report-winnie.pdf>

[6] Franconeri, S. L., Padilla, L. M., Shah, P., Zacks, J. M., & Hullman, J. (2021). The Science of Visual Data Communication: What Works. *Psychological Science in the Public Interest*, 22(3), 110–161. <https://doi.org/10.1177/15291006211051956>

## 21. Anexos

Em anexo encontra-se o código ETL referente ao tratamento de dados efetuado ao dataset escolhido para a realização do projeto. Posto isto, é visível o código referente às três fases (Bronze, Silver e Gold):

```
# Install dependencies

import sys
!{sys.executable} -m pip install hdfs

Requirement already satisfied: hdfs in /opt/conda/lib/python3.10/site-packages (2.7.0)
Requirement already satisfied: six>=1.9.0 in /opt/conda/lib/python3.10/site-packages (from hdfs) (1.16.0)
Requirement already satisfied: requests>=2.7.0 in /opt/conda/lib/python3.10/site-packages (from hdfs) (2.28.1)
Requirement already satisfied: docopt in /opt/conda/lib/python3.10/site-packages (from hdfs) (0.6.2)
Requirement already satisfied: certifi>=2017.4.17 in /opt/conda/lib/python3.10/site-packages (from requests>=2.7.0->hdfs) (2022.9.24)
Requirement already satisfied: charset-normalizer<3,>=2 in /opt/conda/lib/python3.10/site-packages (from requests>=2.7.0->hdfs) (2.1.1)
Requirement already satisfied: idna<4,>=2.5 in /opt/conda/lib/python3.10/site-packages (from requests>=2.7.0->hdfs) (3.4)
Requirement already satisfied: urllib3<1.27,>=1.21.1 in /opt/conda/lib/python3.10/site-packages (from requests>=2.7.0->hdfs) (1.26.11)

pip install delta-spark

Requirement already satisfied: delta-spark in /opt/conda/lib/python3.10/site-packages (2.1.0)
Requirement already satisfied: pyspark<3.4.0,>=3.3.0 in /usr/local/spark-3.3.0-bin-hadoop3/python (from delta-spark) (3.3.0)
Requirement already satisfied: importlib-metadata>=1.0.0 in /opt/conda/lib/python3.10/site-packages (from delta-spark) (4.11.4)
Requirement already satisfied: zipp>=0.5 in /opt/conda/lib/python3.10/site-packages (from importlib-metadata>=1.0.0->delta-spark) (3.9.0)
Requirement already satisfied: py4j==0.10.9.5 in /opt/conda/lib/python3.10/site-packages (from pyspark<3.4.0,>=3.3.0->delta-spark) (0.10.9.5)
Note: you may need to restart the kernel to use updated packages.
```

```
from pyspark.sql import SparkSession
from pyspark.sql import Row
from delta import *

# warehouse_location points to the default location for managed databases and tables
warehouse_location = 'hdfs://hdfs-nn:9000/AVI'

builder = SparkSession \
    .builder \
    .appName("Python Spark SQL Hive integration example") \
    .config("spark.sql.warehouse.dir", warehouse_location) \
    .config("hive.metastore.uris", "thrift://hive-metastore:9083") \
    .config("spark.sql.extensions", "io.delta.sql.DeltaSparkSessionExtension") \
    .config("spark.sql.catalog.spark_catalog", "org.apache.spark.sql.delta.catalog.DeltaCatalog") \
    .config("spark.jars.packages", "io.delta:delta-core_2.12:1.0.0") \
    .enableHiveSupport() \

spark = spark = configure_spark_with_delta_pip(builder).getOrCreate()
```

## Bronze

```
# upload sales and products to bronze

from os import PathLike
from hdfs import InsecureClient
client = InsecureClient("http://hdfs-nn:9870", user="anonymous")

from_path = "./911.csv"
to_path = "/AVI/bronze/911.csv"

client.delete(to_path)

client.upload(to_path, from_path)

# More HDFS functions here if needed (e.g., read, write, list files, delete files, rename, delete, etc...)
# https://hdfsccli.readthedocs.io/en/latest/quickstart.html
```

## Silver

```
spark.sql(
    """
    DROP DATABASE IF EXISTS silver CASCADE
    """
)
```

DataFrame[]

```
# create silver database
spark.sql(
    """
    CREATE DATABASE IF NOT EXISTS silver_911 LOCATION 'hdfs://hdfs-nn:9000/AVI/silver/silver_911.db/'
    """
)
```

DataFrame[]

```
# create products table in silver
spark.sql(
    """
    DROP TABLE IF EXISTS silver_911.EmergencyCalls
    """
)
```

```

spark.sql(
  """
  CREATE EXTERNAL TABLE silver_911.EmergencyCalls (
    lat FLOAT,
    lng FLOAT,
    zip INT,
    town VARCHAR(50),
    arrival_date VARCHAR(50),
    arrival_time VARCHAR(50),
    call_date VARCHAR(50),
    call_time VARCHAR(50),
    hour INT,
    type VARCHAR(50),
    reply_time VARCHAR(50),
    reply_time_avg VARCHAR(50)

  )
  USING DELTA

  LOCATION 'hdfs://hdfs-nn:9000/AVI/silver/silver_911.db/EmergencyCalls/'
  """
)

```

DataFrame[]

```

spark.sql("USE silver_911")
spark.sql("SHOW tables").show()

```

```

+-----+-----+-----+
| namespace|    tableName|isTemporary|
+-----+-----+-----+
|silver_911|emergencycalls|      false|
+-----+-----+-----+

```

```
from pyspark.sql.functions import col
```

```
call = spark \
    .read \
    .option("header", True) \
    .option("inferSchema", True) \
    .csv("hdfs://hdfs-nn:9000/AVI/bronze/911.csv")
```

```
from pyspark.sql.functions import *
```

```
call = call.drop("e")
call.show()
```

| lat        | lng         | desc                  | zip   | title                | timeStamp           | twp               | addr                  |
|------------|-------------|-----------------------|-------|----------------------|---------------------|-------------------|-----------------------|
| 40.2978759 | -75.5812935 | REINDEER CT & DEA...  | 19525 | EMS: BACK PAINS/I... | 2015-12-10 17:40:00 | NEW HANOVER       | REINDEER CT & DEA...  |
| 40.2580614 | -75.2646799 | BRIAR PATH & WHIT...  | 19446 | EMS: DIABETIC EME... | 2015-12-10 17:40:00 | HATFIELD TOWNSHIP | BRIAR PATH & WHIT...  |
| 40.1211818 | -75.3519752 | HAMS AVE; NORRIST...  | 19401 | Fire: GAS-ODOR/LEAK  | 2015-12-10 17:40:00 | NORRISTOWN        | HAMS AVE              |
| 40.116153  | -75.343513  | AIRY ST & SWEDE S...  | 19401 | EMS: CARDIAC EMER... | 2015-12-10 17:40:01 | NORRISTOWN        | AIRY ST & SWEDE ST    |
| 40.251492  | -75.6033497 | CHERRYWOOD CT & D...  | null  | EMS: DIZZINESS       | 2015-12-10 17:40:01 | LOWER POTTS GROVE | CHERRYWOOD CT & D...  |
| 40.2534732 | -75.283245  | CANNON AVE & W 9T...  | 19446 | EMS: HEAD INJURY     | 2015-12-10 17:40:01 | LANSDALE          | CANNON AVE & W 9T...  |
| 40.1821111 | -75.1277951 | LAUREL AVE & OAKD...  | 19044 | EMS: NAUSEA/VOMITING | 2015-12-10 17:40:01 | HORSHAM           | LAUREL AVE & OAKD...  |
| 40.2172859 | -75.405182  | COLLEGEVILLE RD & ... | 19426 | EMS: RESPIRATORY ... | 2015-12-10 17:40:01 | SKIPPAK           | COLLEGEVILLE RD & ... |
| 40.2890267 | -75.3995896 | MAIN ST & OLD SUM...  | 19438 | EMS: SYNCOPAL EPI... | 2015-12-10 17:40:01 | LOWER SALFORD     | MAIN ST & OLD SUM...  |
| 40.1023985 | -75.2914577 | BLUEROUTE & RAMP...   | 19462 | Traffic: VEHICLE ... | 2015-12-10 17:40:01 | PLYMOUTH          | BLUEROUTE & RAMP...   |
| 40.2319898 | -75.2518915 | RT202 PKWY & KNAP...  | null  | Traffic: VEHICLE ... | 2015-12-10 17:40:01 | MONTGOMERY        | RT202 PKWY & KNAP...  |
| 40.0841613 | -75.3083857 | BROOK RD & COLWEL...  | 19428 | Traffic: VEHICLE ... | 2015-12-10 17:40:02 | PLYMOUTH          | BROOK RD & COLWEL...  |
| 40.1741312 | -75.0984907 | BYBERRY AVE & S W...  | 19040 | Traffic: VEHICLE ... | 2015-12-10 17:40:02 | UPPER MORELAND    | BYBERRY AVE & S W...  |
| 40.062974  | -75.135914  | OLD YORK RD & VAL...  | 19027 | Traffic: VEHICLE ... | 2015-12-10 17:40:02 | CHELTENHAM        | OLD YORK RD & VAL...  |
| 40.0972222 | -75.3761952 | SCHUYLKILL EXPY & ... | null  | Traffic: VEHICLE ... | 2015-12-10 17:40:02 | UPPER MERION      | SCHUYLKILL EXPY & ... |
| 40.2237777 | -75.2353993 | STUMP RD & WITCHW...  | 18936 | Traffic: VEHICLE ... | 2015-12-10 17:40:02 | MONTGOMERY        | STUMP RD & WITCHW...  |
| 40.2432578 | -75.2865516 | SUSQUEHANNA AVE & ... | 19446 | EMS: RESPIRATORY ... | 2015-12-10 17:46:01 | LANSDALE          | SUSQUEHANNA AVE & ... |
| 40.3121807 | -75.5742598 | CHARLOTTE ST & MI...  | 19525 | EMS: DIZZINESS       | 2015-12-10 17:47:01 | NEW HANOVER       | CHARLOTTE ST & MI...  |
| 40.114239  | -75.338508  | PENN ST & ARCH ST...  | 19401 | EMS: VEHICLE ACCI... | 2015-12-10 17:47:01 | NORRISTOWN        | PENN ST & ARCH ST     |
| 40.2093369 | -75.1352655 | COUNTY LINE RD & ...  | 18974 | Traffic: DISABLED... | 2015-12-10 17:47:02 | HORSHAM           | COUNTY LINE RD & ...  |

only showing top 20 rows

|  | lat        | lng         | desc                 | zip   | title                | timeStamp           | town              | addr                 |
|--|------------|-------------|----------------------|-------|----------------------|---------------------|-------------------|----------------------|
|  | 40.2978759 | -75.5812935 | REINDEER CT & DEA... | 19525 | EMS: BACK PAINS/I... | 2015-12-10 17:40:00 | NEW HANOVER       | REINDEER CT & DEA... |
|  | 40.2580614 | -75.2646799 | BRIAR PATH & WHIT... | 19446 | EMS: DIABETIC EME... | 2015-12-10 17:40:00 | HATFIELD TOWNSHIP | BRIAR PATH & WHIT... |
|  | 40.1211818 | -75.3519752 | HAWS AVE; NORRIST... | 19401 | Fire: GAS-ODOR/LEAK  | 2015-12-10 17:40:00 | NORRISTOWN        | HAWS AVE             |
|  | 40.116153  | -75.343513  | AIRY ST & SWEDE S... | 19401 | EMS: CARDIAC EMER... | 2015-12-10 17:40:01 | NORRISTOWN        | AIRY ST & SWEDE ST   |
|  | 40.251492  | -75.6033497 | CHERRYWOOD CT & D... | null  | EMS: DIZZINESS       | 2015-12-10 17:40:01 | LOWER POTTS GROVE | CHERRYWOOD CT & D... |
|  | 40.2534732 | -75.283245  | CANNON AVE & W 9T... | 19446 | EMS: HEAD INJURY     | 2015-12-10 17:40:01 | LANDSALE          | CANNON AVE & W 9T... |
|  | 40.1821111 | -75.1277951 | LAUREL AVE & OAKD... | 19044 | EMS: NAUSEA/VOMITING | 2015-12-10 17:40:01 | HORSHAM           | LAUREL AVE & OAKD... |
|  | 40.2172859 | -75.405182  | COLLEGEVILLE RD &... | 19426 | EMS: RESPIRATORY ... | 2015-12-10 17:40:01 | SKIPPACK          | COLLEGEVILLE RD &... |
|  | 40.2890267 | -75.3995896 | MAIN ST & OLD SUM... | 19438 | EMS: SYNCOPAL EPI... | 2015-12-10 17:40:01 | LOWER SALFORD     | MAIN ST & OLD SUM... |
|  | 40.1023985 | -75.2914577 | BLUEROUTE & RAMP...  | 19462 | Traffic: VEHICLE ... | 2015-12-10 17:40:01 | PLYMOUTH          | BLUEROUTE & RAMP...  |
|  | 40.2319898 | -75.2518915 | RT202 PKWY & KNAP... | null  | Traffic: VEHICLE ... | 2015-12-10 17:40:01 | MONTGOMERY        | RT202 PKWY & KNAP... |
|  | 40.0841613 | -75.3083857 | BROOK RD & COLWEL... | 19428 | Traffic: VEHICLE ... | 2015-12-10 17:40:02 | PLYMOUTH          | BROOK RD & COLWEL... |
|  | 40.1741312 | -75.0984907 | BYBERRY AVE & S W... | 19040 | Traffic: VEHICLE ... | 2015-12-10 17:40:02 | UPPER MORELAND    | BYBERRY AVE & S W... |
|  | 40.062974  | -75.135914  | OLD YORK RD & VAL... | 19027 | Traffic: VEHICLE ... | 2015-12-10 17:40:02 | CHELTENHAM        | OLD YORK RD & VAL... |
|  | 40.0972222 | -75.3761952 | SCHUYLKILL EXPY &... | null  | Traffic: VEHICLE ... | 2015-12-10 17:40:02 | UPPER MERION      | SCHUYLKILL EXPY &... |
|  | 40.2237777 | -75.2353993 | STUMP RD & WITCHW... | 18936 | Traffic: VEHICLE ... | 2015-12-10 17:40:02 | MONTGOMERY        | STUMP RD & WITCHW... |
|  | 40.2432578 | -75.2865516 | SUSQUEHANNA AVE &... | 19446 | EMS: RESPIRATORY ... | 2015-12-10 17:40:01 | LANDSALE          | SUSQUEHANNA AVE &... |
|  | 40.3121807 | -75.5742598 | CHARLOTTE ST & MI... | 19525 | EMS: DIZZINESS       | 2015-12-10 17:47:01 | NEW HANOVER       | CHARLOTTE ST & MI... |
|  | 40.114239  | -75.338508  | PENN ST & ARCH ST... | 19401 | EMS: VEHICLE ACCI... | 2015-12-10 17:47:01 | NORRISTOWN        | PENN ST & ARCH ST... |
|  | 40.2093369 | -75.1352655 | COUNTY LINE RD & ... | 18974 | Traffic: DISABLED... | 2015-12-10 17:47:02 | HORSHAM           | COUNTY LINE RD & ... |

only showing top 20 rows

```

...
|-- timeStamp: timestamp (nullable = true)
|-- town: string (nullable = true)
|-- addr: string (nullable = true)

```

```
from pyspark.sql.functions import split

call = call.withColumn('arrival_date', split(call['timeStamp'], ' ').getItem(0))

call.show()
```

only showing top 20 rows



```
from pyspark.sql.functions import split

call = call.withColumn('arrival_time', split(call['timeStamp'], ' ').getItem(1))
call = call.drop('timeStamp')

call.show()
```

|            | lat         | lng   | desc                 | zip | title             | town                 | addr | arrival_date | arrival_time |
|------------|-------------|-------|----------------------|-----|-------------------|----------------------|------|--------------|--------------|
| 40.2978759 | -75.5812935 | 19525 | EMS: BACK PAINS/I... |     | NEW HANOVER       | REINDEER CT & DEA... |      | 2015-12-10   | 17:40:00     |
| 40.2580614 | -75.2646799 | 19446 | EMS: DIABETIC EME... |     | HATFIELD TOWNSHIP | BRIAR PATH & WHIT... |      | 2015-12-10   | 17:40:00     |
| 40.1211818 | -75.3519752 | 19401 | Fire: GAS-ODOR/LEAK  |     | NORRISTOWN        | HAWS AVE             |      | 2015-12-10   | 17:40:00     |
| 40.116153  | -75.343513  | 19401 | EMS: CARDIAC EMER... |     | NORRISTOWN        | AIRY ST & SWEDE ST   |      | 2015-12-10   | 17:40:01     |
| 40.251492  | -75.6033497 |       | EMS: DIZZINESS       |     | LOWER POTTS GROVE | CHERRYWOOD CT & D... |      | 2015-12-10   | 17:40:01     |
| 40.2534732 | -75.283245  | 19446 | EMS: HEAD INJURY     |     | LANSDALE          | CANNON AVE & W 9T... |      | 2015-12-10   | 17:40:01     |
| 40.1821111 | -75.1277951 | 19044 | EMS: NAUSEA/VOMITING |     | HORSHAM           | LAUREL AVE & OAKD... |      | 2015-12-10   | 17:40:01     |
| 40.2172859 | -75.405182  | 19426 | EMS: RESPIRATORY ... |     | SKIPPACK          | COLLEGEVILLE RD &... |      | 2015-12-10   | 17:40:01     |
| 40.2890267 | -75.3995896 | 19438 | EMS: SYNCOPAL EPI... |     | LOWER SALFORD     | MAIN ST & OLD SUM... |      | 2015-12-10   | 17:40:01     |
| 40.1023985 | -75.2914577 | 19462 | Traffic: VEHICLE ... |     | PLYMOUTH          | BLUEROUTE & RAMP...  |      | 2015-12-10   | 17:40:01     |
| 40.2319898 | -75.2518915 |       | Traffic: VEHICLE ... |     | MONTGOMERY        | RT202 PKWY & KNAP... |      | 2015-12-10   | 17:40:01     |
| 40.0841613 | -75.3083857 | 19428 | Traffic: VEHICLE ... |     | PLYMOUTH          | BROOK RD & COLWEL... |      | 2015-12-10   | 17:40:02     |
| 40.1741312 | -75.0984907 | 19040 | Traffic: VEHICLE ... |     | UPPER MORELAND    | BYBERRY AVE & S W... |      | 2015-12-10   | 17:40:02     |
| 40.062974  | -75.135914  | 19027 | Traffic: VEHICLE ... |     | CHELTENHAM        | OLD YORK RD & VAL... |      | 2015-12-10   | 17:40:02     |
| 40.0972222 | -75.3761952 |       | Traffic: VEHICLE ... |     | UPPER MERION      | SCHUYLKILL EXPY &... |      | 2015-12-10   | 17:40:02     |
| 40.2237777 | -75.2353993 | 18936 | Traffic: VEHICLE ... |     | MONTGOMERY        | STUMP RD & WITCHW... |      | 2015-12-10   | 17:40:02     |
| 40.2432578 | -75.2865516 | 19446 | EMS: RESPIRATORY ... |     | LANSDALE          | SUSQUEHANNA AVE &... |      | 2015-12-10   | 17:46:01     |
| 40.3121807 | -75.5742598 | 19525 | EMS: DIZZINESS       |     | NEW HANOVER       | CHARLOTTE ST & MI... |      | 2015-12-10   | 17:47:01     |
| 40.114239  | -75.338508  | 19401 | EMS: VEHICLE ACCI... |     | NORRISTOWN        | PENN ST & ARCH ST    |      | 2015-12-10   | 17:47:01     |
| 40.2093369 | -75.1352655 | 18974 | Traffic: DISABLED... |     | HORSHAM           | COUNTY LINE RD & ... |      | 2015-12-10   | 17:47:02     |

only showing top 20 rows

```
from pyspark.sql.functions import when, regexp_extract

# Use expressões regulares para extrair a data e a hora, independentemente de sua posição
date_expr = r'(\d{4}-\d{2}-\d{2}) @ (\d{2}:\d{2}:\d{2})|(\d{4}-\d{2}-\d{2} \d{2}:\d{2}:\d{2})'

# Use regexp_extract para extrair a data e a hora e trate os casos em que não há correspondência
call = call.withColumn('data_hora', regexp_extract(call['desc'], date_expr, 0))
call = call.withColumn('call_date', when(call['data_hora'] != '', regexp_extract(call['data_hora'], r'(\d{4}-\d{2}-\d{2})', 0)).otherwise(None))
call = call.withColumn('call_time', when(call['data_hora'] != '', regexp_extract(call['data_hora'], r'(\d{2}:\d{2}:\d{2})', 0)).otherwise(None))
call = call.drop('data_hora')
# Agora você deve ter as colunas 'data' e 'hora' separadas corretamente, e elas conterão "null" quando não houver correspondência.
```

```
from pyspark.sql.functions import *

call = call.drop("desc")
call.show()
```

|            | lat         | lng   | zip                  | title | town              | addr                 | arrival_date | arrival_time | call_date  | call_time |
|------------|-------------|-------|----------------------|-------|-------------------|----------------------|--------------|--------------|------------|-----------|
| 40.2978759 | -75.5812935 | 19525 | EMS: BACK PAINS/I... |       | NEW HANOVER       | REINDEER CT & DEA... | 2015-12-10   | 17:40:00     | 2015-12-10 | 17:10:52  |
| 40.2580614 | -75.2646799 | 19446 | EMS: DIABETIC EME... |       | HATFIELD TOWNSHIP | BRIAR PATH & WHIT... | 2015-12-10   | 17:40:00     | 2015-12-10 | 17:29:21  |
| 40.1211818 | -75.3519752 | 19401 | Fire: GAS-ODOR/LEAK  |       | NORRISTOWN        | HAWS AVE             | 2015-12-10   | 17:40:00     | 2015-12-10 | 14:39:21  |
| 40.116153  | -75.343513  | 19401 | EMS: CARDIAC EMER... |       | NORRISTOWN        | AIRY ST & SWEDE ST   | 2015-12-10   | 17:40:01     | 2015-12-10 | 16:47:36  |
| 40.251492  | -75.6033497 |       | EMS: DIZZINESS       |       | LOWER POTTS GROVE | CHERRYWOOD CT & D... | 2015-12-10   | 17:40:01     | 2015-12-10 | 16:56:52  |
| 40.2534732 | -75.283245  | 19446 | EMS: HEAD INJURY     |       | LANSDALE          | CANNON AVE & W 9T... | 2015-12-10   | 17:40:01     | 2015-12-10 | 15:39:04  |
| 40.1821111 | -75.1277951 | 19044 | EMS: NAUSEA/VOMITING |       | HORSHAM           | LAUREL AVE & OAKD... | 2015-12-10   | 17:40:01     | 2015-12-10 | 16:46:48  |
| 40.2172859 | -75.405182  | 19426 | EMS: RESPIRATORY ... |       | SKIPPACK          | COLLEGEVILLE RD &... | 2015-12-10   | 17:40:01     | 2015-12-10 | 16:17:05  |
| 40.2890267 | -75.3995896 | 19438 | EMS: SYNCOPAL EPI... |       | LOWER SALFORD     | MAIN ST & OLD SUM... | 2015-12-10   | 17:40:01     | 2015-12-10 | 16:51:42  |
| 40.1023985 | -75.2914577 | 19462 | Traffic: VEHICLE ... |       | PLYMOUTH          | BLUEROUTE & RAMP...  | 2015-12-10   | 17:40:01     | 2015-12-10 | 17:35:41  |
| 40.2319898 | -75.2518915 |       | Traffic: VEHICLE ... |       | MONTGOMERY        | RT202 PKWY & KNAP... | 2015-12-10   | 17:40:01     | 2015-12-10 | 17:33:50  |
| 40.0841613 | -75.3083857 | 19428 | Traffic: VEHICLE ... |       | PLYMOUTH          | BROOK RD & COLWEL... | 2015-12-10   | 17:40:02     | 2015-12-10 | 16:32:10  |
| 40.1741312 | -75.0984907 | 19040 | Traffic: VEHICLE ... |       | UPPER MORELAND    | BYBERRY AVE & S W... | 2015-12-10   | 17:40:02     | 2015-12-10 | 17:15:49  |
| 40.062974  | -75.135914  | 19027 | Traffic: VEHICLE ... |       | CHELTENHAM        | OLD YORK RD & VAL... | 2015-12-10   | 17:40:02     | 2015-12-10 | 17:12:47  |
| 40.0972222 | -75.3761952 |       | Traffic: VEHICLE ... |       | UPPER MERION      | SCHUYLKILL EXPY &... | 2015-12-10   | 17:40:02     | 2015-12-10 | 17:09:49  |
| 40.2237777 | -75.2353993 | 18936 | Traffic: VEHICLE ... |       | MONTGOMERY        | STUMP RD & WITCHW... | 2015-12-10   | 17:40:02     | 2015-12-10 | 17:31:00  |
| 40.2432578 | -75.2865516 | 19446 | EMS: RESPIRATORY ... |       | LANSDALE          | SUSQUEHANNA AVE &... | 2015-12-10   | 17:46:01     | 2015-12-10 | 17:42:44  |
| 40.3121807 | -75.5742598 | 19525 | EMS: DIZZINESS       |       | NEW HANOVER       | CHARLOTTE ST & MI... | 2015-12-10   | 17:47:01     | 2015-12-10 | 17:41:54  |
| 40.114239  | -75.338508  | 19401 | EMS: VEHICLE ACCI... |       | NORRISTOWN        | PENN ST & ARCH ST    | 2015-12-10   | 17:47:01     | 2015-12-10 | 17:43:29  |
| 40.2093369 | -75.1352655 | 18974 | Traffic: DISABLED... |       | HORSHAM           | COUNTY LINE RD & ... | 2015-12-10   | 17:47:02     | 2015-12-10 | 17:45:23  |



```

from pyspark.sql.functions import col, substring

# Assumindo que você já possui o DataFrame 'call'

# Extrair a parte da hora da coluna 'call_time' e criar a coluna 'hour'
call = call.withColumn(
    "hour",
    substring(col("call_time"), 1, 2) # Extraí os primeiros dois caracteres (hora)
)

```

```

call = call.withColumn("hour", call["hour"].cast("integer"))

```

```

from pyspark.sql.functions import split

call = call.withColumn('type', split(call['title'], ':').getItem(0))

call.show()

```

| lat        | lng         | zip   | title                | town              | addr                  | arrival_date | arrival_time | call_date  | call_time | hour | type    |
|------------|-------------|-------|----------------------|-------------------|-----------------------|--------------|--------------|------------|-----------|------|---------|
| 40.2978759 | -75.5812935 | 19525 | EMS: BACK PAINS/I... | NEW HANOVER       | REINDEER CT & DEA...  | 2015-12-10   | 17:40:00     | 2015-12-10 | 17:10:52  | 17   | EMS     |
| 40.2580614 | -75.2646799 | 19446 | EMS: DIABETIC EME... | HATFIELD TOWNSHIP | BRIAR PATH & WHIT...  | 2015-12-10   | 17:40:00     | 2015-12-10 | 17:29:21  | 17   | EMS     |
| 40.1211818 | -75.3519752 | 19401 | Fire: GAS-ODOR/LEAK  | NORRISTOWN        | HAWS AVE              | 2015-12-10   | 17:40:00     | 2015-12-10 | 14:39:21  | 14   | Fire    |
| 40.116153  | -75.343513  | 19401 | EMS: CARDIAC EMER... | NORRISTOWN        | AIRY ST & SWEDE ST    | 2015-12-10   | 17:40:01     | 2015-12-10 | 16:47:36  | 16   | EMS     |
| 40.251492  | -75.6033497 | null  | EMS: DIZZINESS       | LOWER POTTSBORO   | CHERRYWOOD CT & D...  | 2015-12-10   | 17:40:01     | 2015-12-10 | 16:56:52  | 16   | EMS     |
| 40.2534732 | -75.283245  | 19446 | EMS: HEAD INJURY     | LANSDALE          | CANNON AVE & W 9T...  | 2015-12-10   | 17:40:01     | 2015-12-10 | 15:39:04  | 15   | EMS     |
| 40.1821111 | -75.1277951 | 19044 | EMS: NAUSEA/VOMITING | HORSHAM           | LAUREL AVE & OAKD...  | 2015-12-10   | 17:40:01     | 2015-12-10 | 16:46:48  | 16   | EMS     |
| 40.2172859 | -75.405182  | 19426 | EMS: RESPIRATORY ... | SKIPPAK           | COLLEGEVILLE RD & ... | 2015-12-10   | 17:40:01     | 2015-12-10 | 16:17:05  | 16   | EMS     |
| 40.2890267 | -75.3995896 | 19438 | EMS: SYNCOPAL EPI... | LOWER SALFORD     | MAIN ST & OLD SUM...  | 2015-12-10   | 17:40:01     | 2015-12-10 | 16:51:42  | 16   | EMS     |
| 40.1023985 | -75.2914577 | 19462 | Traffic: VEHICLE ... | PLYMOUTH          | BLUEROUTE & RAMP...   | 2015-12-10   | 17:40:01     | 2015-12-10 | 17:35:41  | 17   | Traffic |
| 40.2319898 | -75.2518915 | null  | Traffic: VEHICLE ... | MONTGOMERY        | RT202 PKWY & KNAP...  | 2015-12-10   | 17:40:01     | 2015-12-10 | 17:33:50  | 17   | Traffic |
| 40.0841613 | -75.3083857 | 19428 | Traffic: VEHICLE ... | PLYMOUTH          | BROOK RD & COLWEL...  | 2015-12-10   | 17:40:02     | 2015-12-10 | 16:32:10  | 16   | Traffic |
| 40.1741312 | -75.0984907 | 19040 | Traffic: VEHICLE ... | UPPER MORELAND    | BYBERRY AVE & S W...  | 2015-12-10   | 17:40:02     | 2015-12-10 | 17:15:49  | 17   | Traffic |
| 40.062974  | -75.135914  | 19027 | Traffic: VEHICLE ... | CHELTHENHAM       | OLD YORK RD & VAL...  | 2015-12-10   | 17:40:02     | 2015-12-10 | 17:12:47  | 17   | Traffic |
| 40.0972222 | -75.3761952 | null  | Traffic: VEHICLE ... | UPPER MERION      | SCHUYLKILL EXPY & ... | 2015-12-10   | 17:40:02     | 2015-12-10 | 17:09:49  | 17   | Traffic |
| 40.2237777 | -75.2353993 | 18936 | Traffic: VEHICLE ... | MONTGOMERY        | STUMP RD & WITCHN...  | 2015-12-10   | 17:40:02     | 2015-12-10 | 17:31:00  | 17   | Traffic |
| 40.2432578 | -75.2865516 | 19446 | EMS: RESPIRATORY ... | LANSDALE          | SUSQUEHANNA AVE & ... | 2015-12-10   | 17:46:01     | 2015-12-10 | 17:42:44  | 17   | EMS     |
| 40.3121807 | -75.5742598 | 19525 | EMS: DIZZINESS       | NEW HANOVER       | CHARLOTTE ST & MI...  | 2015-12-10   | 17:47:01     | 2015-12-10 | 17:41:54  | 17   | EMS     |
| 40.114239  | -75.338508  | 19401 | EMS: VEHICLE ACCI... | NORRISTOWN        | PENN ST & ARCH ST     | 2015-12-10   | 17:47:01     | 2015-12-10 | 17:43:29  | 17   | EMS     |
| 40.2093369 | -75.1352655 | 18974 | Traffic: DISABLED... | HORSHAM           | COUNTY LINE RD & ...  | 2015-12-10   | 17:47:02     | 2015-12-10 | 17:45:23  | 17   | Traffic |

only showing top 20 rows

```

from pyspark.sql.functions import split

call = call.withColumn('title', split(call['title'], ':').getItem(1))

call.show()

```

|  | lat        | lng         | zip   | title               | town              | addr                 | arrival_date | arrival_time | call_date  | call_time | hour | type    |
|--|------------|-------------|-------|---------------------|-------------------|----------------------|--------------|--------------|------------|-----------|------|---------|
|  | 40.2978759 | -75.5812935 | 19525 | BACK PAINS/INJURY   | NEW HANOVER       | REINDEER CT & DEA... | 2015-12-10   | 17:40:00     | 2015-12-10 | 17:10:52  | 17   | EMS     |
|  | 40.2580614 | -75.2646799 | 19446 | DIABETIC EMERGENCY  | HATFIELD TOWNSHIP | BRIAR PATH & WHIT... | 2015-12-10   | 17:40:00     | 2015-12-10 | 17:29:21  | 17   | EMS     |
|  | 40.1211818 | -75.3519752 | 19401 | GAS-ODOR/LEAK       | NORRISTOWN        | HAWS AVE             | 2015-12-10   | 17:40:00     | 2015-12-10 | 14:39:21  | 14   | Fire    |
|  | 40.116153  | -75.343513  | 19401 | CARDIAC EMERGENCY   | NORRISTOWN        | AIRY ST & SWEDE ST   | 2015-12-10   | 17:40:01     | 2015-12-10 | 16:47:36  | 16   | EMS     |
|  | 40.251492  | -75.6033497 | null  | DIZZINESS           | LOWER POTTS GROVE | CHERRYWOOD CT & D... | 2015-12-10   | 17:40:01     | 2015-12-10 | 16:56:52  | 16   | EMS     |
|  | 40.2534732 | -75.283245  | 19446 | HEAD INJURY         | LAINDALE          | CANNON AVE & W 9T... | 2015-12-10   | 17:40:01     | 2015-12-10 | 15:39:04  | 15   | EMS     |
|  | 40.1821111 | -75.1277951 | 19044 | NAUSEA/VOMITING     | HORSHAM           | LAUREL AVE & OAKD... | 2015-12-10   | 17:40:01     | 2015-12-10 | 16:46:48  | 16   | EMS     |
|  | 40.2172859 | -75.405182  | 19426 | RESPIRATORY EMER... | SKIPPACK          | COLLEGEVILLE RD &... | 2015-12-10   | 17:40:01     | 2015-12-10 | 16:17:05  | 16   | EMS     |
|  | 40.2890267 | -75.3995896 | 19438 | SYNCOPE EPISODE     | LOWER SALFORD     | MAIN ST & OLD SUM... | 2015-12-10   | 17:40:01     | 2015-12-10 | 16:51:42  | 16   | EMS     |
|  | 40.1023985 | -75.2914577 | 19462 | VEHICLE ACCIDENT -  | PLYMOUTH          | BLUEROUTE & RAMP...  | 2015-12-10   | 17:40:01     | 2015-12-10 | 17:35:41  | 17   | Traffic |
|  | 40.2319898 | -75.2518915 | null  | VEHICLE ACCIDENT -  | MONTGOMERY        | RT202 PKWY & KNAP... | 2015-12-10   | 17:40:01     | 2015-12-10 | 17:33:50  | 17   | Traffic |
|  | 40.0841613 | -75.3083857 | 19428 | VEHICLE ACCIDENT -  | PLYMOUTH          | BROOK RD & COLWEL... | 2015-12-10   | 17:40:02     | 2015-12-10 | 16:32:10  | 16   | Traffic |
|  | 40.1741312 | -75.0984907 | 19040 | VEHICLE ACCIDENT -  | UPPER MORELAND    | BYBERRY AVE & S W... | 2015-12-10   | 17:40:02     | 2015-12-10 | 17:15:49  | 17   | Traffic |
|  | 40.062974  | -75.135914  | 19027 | VEHICLE ACCIDENT -  | CHELTENHAM        | OLD YORK RD & VAL... | 2015-12-10   | 17:40:02     | 2015-12-10 | 17:12:47  | 17   | Traffic |
|  | 40.0972222 | -75.3761952 | null  | VEHICLE ACCIDENT -  | UPPER MERION      | SCHUYLKILL EXPY &... | 2015-12-10   | 17:40:02     | 2015-12-10 | 17:09:49  | 17   | Traffic |
|  | 40.2237777 | -75.2353993 | 18936 | VEHICLE ACCIDENT -  | MONTGOMERY        | STUMP RD & WITCHW... | 2015-12-10   | 17:40:02     | 2015-12-10 | 17:31:00  | 17   | Traffic |
|  | 40.2432578 | -75.2865516 | 19446 | RESPIRATORY EMER... | LAINDALE          | SUSQUEHANNA AVE &... | 2015-12-10   | 17:46:01     | 2015-12-10 | 17:42:44  | 17   | EMS     |
|  | 40.3121807 | -75.5742598 | 19525 | DIZZINESS           | NEW HANOVER       | CHARLOTTE ST & MI... | 2015-12-10   | 17:47:01     | 2015-12-10 | 17:41:54  | 17   | EMS     |
|  | 40.114239  | -75.338508  | 19401 | VEHICLE ACCIDENT    | NORRISTOWN        | PENN ST & ARCH ST    | 2015-12-10   | 17:47:01     | 2015-12-10 | 17:43:29  | 17   | EMS     |
|  | 40.2093369 | -75.1352655 | 18974 | DISABLED VEHICLE -  | HORSHAM           | COUNTY LINE RD & ... | 2015-12-10   | 17:47:02     | 2015-12-10 | 17:45:23  | 17   | Traffic |

```

call = call.withColumn("zip", call["zip"].cast("integer"))

call = call.withColumn("lat", call["lat"].cast("float"))

call = call.withColumn("lng", call["lng"].cast("float"))

```

```

from pyspark.sql.functions import col, length

```

```

# Remover linhas onde 'zip' é nulo
call = call.na.drop(subset=["zip"])

```

```

from pyspark.sql.functions import col, when, length

```

```

# Substituir espaços em branco por "N/A" na coluna 'zip'
call = call.withColumn("addr", when(length(col("addr")) == 0, "N/A").otherwise(col("addr")))

```

```
from pyspark.sql.functions import *
```

```
call = call.drop("addr")
call.show()
```

| lat       | lng        | zip   | title               | town              | arrival_date | arrival_time | call_date  | call_time | hour | type    |
|-----------|------------|-------|---------------------|-------------------|--------------|--------------|------------|-----------|------|---------|
| 40.297874 | -75.58129  | 19525 | BACK PAINS/INJURY   | NEW HANOVER       | 2015-12-10   | 17:40:00     | 2015-12-10 | 17:10:52  | 17   | EMS     |
| 40.25806  | -75.26468  | 19446 | DIABETIC EMERGENCY  | HATFIELD TOWNSHIP | 2015-12-10   | 17:40:00     | 2015-12-10 | 17:29:21  | 17   | EMS     |
| 40.12118  | -75.351974 | 19401 | GAS-ODOR/LEAK       | NORRISTOWN        | 2015-12-10   | 17:40:00     | 2015-12-10 | 14:39:21  | 14   | Fire    |
| 40.116154 | -75.34351  | 19401 | CARDIAC EMERGENCY   | NORRISTOWN        | 2015-12-10   | 17:40:01     | 2015-12-10 | 16:47:36  | 16   | EMS     |
| 40.25347  | -75.28324  | 19446 | HEAD INJURY         | LANSDALE          | 2015-12-10   | 17:40:01     | 2015-12-10 | 15:39:04  | 15   | EMS     |
| 40.18211  | -75.12779  | 19044 | NAUSEA/VOMITING     | HORSHAM           | 2015-12-10   | 17:40:01     | 2015-12-10 | 16:46:48  | 16   | EMS     |
| 40.217285 | -75.40518  | 19426 | RESPIRATORY EMER... | SKIPPACK          | 2015-12-10   | 17:40:01     | 2015-12-10 | 16:17:05  | 16   | EMS     |
| 40.28903  | -75.39959  | 19438 | SYNCOPE EPISODE     | LOWER SALFORD     | 2015-12-10   | 17:40:01     | 2015-12-10 | 16:51:42  | 16   | EMS     |
| 40.102398 | -75.29146  | 19462 | VEHICLE ACCIDENT -  | PLYMOUTH          | 2015-12-10   | 17:40:01     | 2015-12-10 | 17:35:41  | 17   | Traffic |
| 40.08416  | -75.30839  | 19428 | VEHICLE ACCIDENT -  | PLYMOUTH          | 2015-12-10   | 17:40:02     | 2015-12-10 | 16:32:10  | 16   | Traffic |
| 40.17413  | -75.09849  | 19040 | VEHICLE ACCIDENT -  | UPPER MORELAND    | 2015-12-10   | 17:40:02     | 2015-12-10 | 17:15:49  | 17   | Traffic |
| 40.062973 | -75.13592  | 19027 | VEHICLE ACCIDENT -  | CHELTENHAM        | 2015-12-10   | 17:40:02     | 2015-12-10 | 17:12:47  | 17   | Traffic |
| 40.223778 | -75.2354   | 18936 | VEHICLE ACCIDENT -  | MONTGOMERY        | 2015-12-10   | 17:40:02     | 2015-12-10 | 17:31:00  | 17   | Traffic |
| 40.24326  | -75.28655  | 19446 | RESPIRATORY EMER... | LANSDALE          | 2015-12-10   | 17:46:01     | 2015-12-10 | 17:42:44  | 17   | EMS     |
| 40.31218  | -75.57426  | 19525 | DIZZINESS           | NEW HANOVER       | 2015-12-10   | 17:47:01     | 2015-12-10 | 17:41:54  | 17   | EMS     |
| 40.11424  | -75.33851  | 19401 | VEHICLE ACCIDENT    | NORRISTOWN        | 2015-12-10   | 17:47:01     | 2015-12-10 | 17:43:29  | 17   | EMS     |
| 40.209335 | -75.13527  | 18974 | DISABLED VEHICLE -  | HORSHAM           | 2015-12-10   | 17:47:02     | 2015-12-10 | 17:45:23  | 17   | Traffic |
| 40.11424  | -75.33851  | 19401 | VEHICLE ACCIDENT -  | NORRISTOWN        | 2015-12-10   | 17:47:02     | 2015-12-10 | 17:43:45  | 17   | Traffic |
| 40.117947 | -75.20985  | 19031 | DISABLED VEHICLE -  | WHITEMARSH        | 2015-12-10   | 17:57:02     | 2015-12-10 | 17:53:22  | 17   | Traffic |
| 40.199005 | -75.30006  | 19446 | APPLIANCE FIRE      | UPPER Gwynedd     | 2015-12-10   | 18:02:01     | 2015-12-10 | 17:59:24  | 17   | Fire    |

only showing top 20 rows

```
from pyspark.sql.functions import col, when, length
```

```
# Substituir espaços em branco por "N/A" na coluna 'zip'
call = call.withColumn("town", when(length(col("town")) == 0, "N/A").otherwise(col("town")))
```

```
from pyspark.sql.functions import col, when, unix_timestamp, expr, concat, lpad
```

```
# Assumindo que você já possui o DataFrame 'call'
```

```
from pyspark.sql.functions import col, expr, concat, lpad, unix_timestamp, when
```

```
# Assumindo que você já possui o DataFrame 'call'
```

```
call = call.withColumn(
    "reply_time",
    when(
        col("arrival_date") == col("call_date"),
        (unix_timestamp("arrival_time", "HH:mm:ss") - unix_timestamp("call_time", "HH:mm:ss"))
    ).otherwise(
        (24 * 3600) - (unix_timestamp("arrival_time", "HH:mm:ss") - unix_timestamp("call_time", "HH:mm:ss"))
    )
)
```

```
# Converter a diferença em HH:mm:ss
```

```
call = call.withColumn(
    "reply_time",
    expr("from_unixtime(reply_time, 'HH:mm:ss')")
)
```

```
# Remova os duplicados se necessário
```

```
call = call.dropDuplicates()
```

```

from pyspark.sql import functions as F
from pyspark.sql.types import IntegerType

# Assumindo que você já possui o DataFrame 'call' com as colunas 'reply_time' e 'zip' corretamente calculadas

def time_to_seconds(time_col):
    if time_col is not None and ':' in time_col:
        hours, minutes, seconds = time_col.split(":")
        return int(hours) * 3600 + int(minutes) * 60 + int(seconds)
    else:
        return 0 # ou qualquer outro valor padrão para casos nulos/vazios

# Converter a coluna reply_time para segundos
time_to_seconds_udf = F.udf(time_to_seconds, IntegerType())
call = call.withColumn("reply_time_seconds", time_to_seconds_udf("reply_time"))

# Calcular a média dos tempos de resposta por cidade em segundos
avg_reply_time_df = call.groupBy("zip").agg(
    F.avg("reply_time_seconds").alias("avg_reply_time_seconds")
)

# Arredondar a média para o formato HH:mm:ss
avg_reply_time_df = avg_reply_time_df.withColumn(
    "reply_time_avg_seconds",
    F.col("avg_reply_time_seconds").cast("int")
).withColumn(
    "reply_time_avg",
    F.expr("from_unixtime(reply_time_avg_seconds, 'HH:mm:ss')")
).select("zip", "reply_time_avg")

# Juntar o DataFrame original com a média de reply_time por cidade
call = call.join(avg_reply_time_df, "zip", "left")

# Remover a coluna temporária reply_time_seconds
call = call.drop("reply_time_seconds")

# Exibir o DataFrame resultante
call.show()

```

| zip     | lat         | lng          | title               | town              | arrival_date | arrival_time | call_date  | call_time | hour | type    | reply_time | reply_time_avg |
|---------|-------------|--------------|---------------------|-------------------|--------------|--------------|------------|-----------|------|---------|------------|----------------|
| [19403] | [40.166306] | [-75.42029]  | UNCONSCIOUS SUBJECT | LOWER PROVIDENCE  | 2015-12-11   | 01:07:01     | 2015-12-11 | 01:05:27  | 1    | EMS     | 00:01:34   | 00:06:16       |
| [19401] | [40.125584] | [-75.320526] | RESPIRATORY EMER... | NORRISTOWN        | 2015-12-11   | 03:07:01     | 2015-12-11 | 03:02:34  | 3    | EMS     | 00:04:27   | 00:06:15       |
| [19090] | [40.13646]  | [-75.12711]  | ABDOMINAL PAINS     | ABINGTON          | 2015-12-11   | 12:57:01     | 2015-12-11 | 12:51:24  | 12   | EMS     | 00:05:37   | 00:05:19       |
| [19454] | [40.240784] | [-75.22393]  | BUILDING FIRE       | MONTGOMERY        | 2015-12-11   | 18:02:01     | 2015-12-11 | 17:58:29  | 17   | Fire    | 00:03:32   | 00:05:52       |
| [18074] | [40.298023] | [-75.46529]  | VEHICLE ACCIDENT -  | LOWER FREDERICK   | 2015-12-11   | 18:07:02     | 2015-12-11 | 18:05:22  | 18   | Traffic | 00:01:40   | 00:03:40       |
| [19004] | [40.005547] | [-75.2367]   | VEHICLE ACCIDENT -  | LOWER MERION      | 2015-12-11   | 18:07:02     | 2015-12-11 | 18:02:14  | 18   | Traffic | 00:04:48   | 00:08:09       |
| [19044] | [40.174973] | [-75.13842]  | DISABLED VEHICLE -  | HORSHAM           | 2015-12-12   | 14:12:01     | 2015-12-12 | 14:06:42  | 14   | Traffic | 00:05:19   | 00:07:21       |
| [19090] | [40.143185] | [-75.11915]  | SUBJECT IN PAIN     | UPPER MORELAND    | 2015-12-12   | 21:42:01     | 2015-12-12 | 21:39:03  | 21   | EMS     | 00:02:58   | 00:05:19       |
| [19464] | [40.279938] | [-75.604576] | HEAD INJURY         | LOWER POTTS GROVE | 2015-12-13   | 11:22:00     | 2015-12-13 | 11:20:48  | 11   | EMS     | 00:01:12   | 00:07:20       |
| [19426] | [40.180782] | [-75.428986] | VEHICLE ACCIDENT -  | LOWER PROVIDENCE  | 2015-12-13   | 12:37:02     | 2015-12-13 | 12:34:37  | 12   | Traffic | 00:02:25   | 00:06:50       |
| [19401] | [40.132713] | [-75.32984]  | FIRE ALARM          | EAST NORRITON     | 2015-12-14   | 06:37:00     | 2015-12-14 | 06:33:14  | 6    | Fire    | 00:03:46   | 00:06:15       |
| [19426] | [40.174564] | [-75.45603]  | RESPIRATORY EMER... | UPPER PROVIDENCE  | 2015-12-15   | 11:57:00     | 2015-12-15 | 11:53:11  | 11   | EMS     | 00:03:49   | 00:06:50       |
| [19440] | [40.27747]  | [-75.26046]  | VEHICLE ACCIDENT -  | HATFIELD TOWNSHIP | 2015-12-15   | 18:22:03     | 2015-12-15 | 18:18:17  | 18   | Traffic | 00:03:46   | 00:03:44       |
| [19468] | [40.168537] | [-75.4982]   | RESPIRATORY EMER... | UPPER PROVIDENCE  | 2015-12-15   | 20:12:02     | 2015-12-15 | 20:06:09  | 20   | EMS     | 00:05:53   | 00:04:54       |
| [19422] | [40.133392] | [-75.25837]  | UNRESPONSIVE SUB... | WHITPAIN          | 2015-12-16   | 08:02:02     | 2015-12-16 | 08:00:07  | 8    | EMS     | 00:01:55   | 00:04:39       |
| [19446] | [40.247074] | [-75.305435] | CVA/STROKE          | TOWAMENCIN        | 2015-12-16   | 08:57:00     | 2015-12-16 | 08:54:39  | 8    | EMS     | 00:02:21   | 00:05:54       |
| [19525] | [40.332596] | [-75.61604]  | CVA/STROKE          | DOUGLASS          | 2015-12-16   | 10:32:01     | 2015-12-16 | 10:28:11  | 10   | EMS     | 00:03:50   | 00:08:32       |
| [19075] | [40.102055] | [-75.18904]  | RESPIRATORY EMER... | SPRINGFIELD       | 2015-12-16   | 17:42:02     | 2015-12-16 | 17:37:09  | 17   | EMS     | 00:04:53   | 00:03:40       |
| [19001] | [40.08093]  | [-75.116394] | VEHICLE ACCIDENT    | ABINGTON          | 2015-12-16   | 18:16:01     | 2015-12-16 | 18:15:21  | 18   | EMS     | 00:00:40   | 00:04:35       |
| [19085] | [40.04906]  | [-75.33677]  | UNKNOWN MEDICAL ... | LOWER MERION      | 2015-12-16   | 20:21:01     | 2015-12-16 | 20:16:20  | 20   | EMS     | 00:04:41   | 00:04:36       |

only showing top 20 rows

```
call.printSchema()
```

```
root
```

```
|-- zip: integer (nullable = true)
|-- lat: float (nullable = true)
|-- lng: float (nullable = true)
|-- title: string (nullable = true)
|-- town: string (nullable = true)
|-- arrival_date: string (nullable = true)
|-- arrival_time: string (nullable = true)
|-- call_date: string (nullable = true)
|-- call_time: string (nullable = true)
|-- hour: integer (nullable = true)
|-- type: string (nullable = true)
|-- reply_time: string (nullable = true)
|-- reply_time_avg: string (nullable = true)
```

```
# write to delta table
call \
  .select("zip","lat","lng","title","town","arrival_date","arrival_time","call_date","call_time","hour","type","reply_time","reply_time_avg") \
  .write \
  .format("delta") \
  .mode("overwrite") \
  .partitionBy("type") \
  .option("overwriteSchema", "true") \
  .save("hdfs://hdfs-nn:9000/AVI/silver/silver_911.db/EmergencyCalls/")

# check the results in the table
spark.table("silver_911.EmergencyCalls").show()
spark.table("silver_911.EmergencyCalls").count()
```

| zip   | lat       | lng        | title               | town              | arrival_date | arrival_time | call_date  | call_time | hour | type | reply_time | reply_time_avg |
|-------|-----------|------------|---------------------|-------------------|--------------|--------------|------------|-----------|------|------|------------|----------------|
| 19464 | 40.245007 | -75.59305  | UNKNOWN MEDICAL ... | LOWER POTTS GROVE | 2015-12-10   | 20:12:01     | 2015-12-10 | 20:09:47  | 20   | EMS  | 00:02:14   | 00:07:20       |
| 18073 | 40.401764 | -75.486176 | ALLERGIC REACTION   | UPPER HANOVER     | 2015-12-11   | 13:02:01     | 2015-12-11 | 13:00:38  | 13   | EMS  | 00:01:23   | 00:15:38       |
| 19038 | 40.080914 | -75.20267  | UNRESPONSIVE SUB... | SPRINGFIELD       | 2015-12-11   | 18:22:01     | 2015-12-11 | 18:16:19  | 18   | EMS  | 00:05:42   | 00:06:57       |
| 19038 | 40.085735 | -75.18736  | FALL VICTIM         | SPRINGFIELD       | 2015-12-12   | 06:17:00     | 2015-12-12 | 06:14:21  | 6    | EMS  | 00:02:39   | 00:06:57       |
| 19090 | 40.150894 | -75.12744  | OVERDOSE            | UPPER MORELAND    | 2015-12-12   | 19:07:01     | 2015-12-12 | 19:05:12  | 19   | EMS  | 00:01:49   | 00:05:19       |
| 19406 | 40.08896  | -75.40835  | RESPIRATORY EMER... | UPPER MERION      | 2015-12-13   | 22:22:01     | 2015-12-13 | 22:18:33  | 22   | EMS  | 00:03:28   | 00:05:32       |
| 19401 | 40.12865  | -75.33133  | CARDIAC EMERGENCY   | NORRISTOWN        | 2015-12-14   | 05:52:01     | 2015-12-14 | 05:49:15  | 5    | EMS  | 00:02:46   | 00:06:15       |
| 19025 | 40.135544 | -75.15384  | UNCONSCIOUS SUBJECT | UPPER DUBLIN      | 2015-12-15   | 10:37:01     | 2015-12-15 | 10:32:50  | 10   | EMS  | 00:04:11   | 00:03:47       |
| 19034 | 40.119476 | -75.24715  | HEMORRHAGING        | WHITEMARSH        | 2015-12-15   | 13:22:00     | 2015-12-15 | 13:18:14  | 13   | EMS  | 00:03:46   | 00:05:33       |
| 19401 | 40.1294   | -75.332214 | RESPIRATORY EMER... | NORRISTOWN        | 2015-12-17   | 10:52:00     | 2015-12-17 | 10:49:57  | 10   | EMS  | 00:02:03   | 00:06:15       |
| 19512 | 40.327347 | -75.623116 | GENERAL WEAKNESS    | DOUGLASS          | 2015-12-17   | 20:57:01     | 2015-12-17 | 20:55:34  | 20   | EMS  | 00:01:27   | 00:03:32       |
| 19464 | 40.246426 | -75.643974 | RESPIRATORY EMER... | POTTSTOWN         | 2015-12-18   | 22:12:01     | 2015-12-18 | 22:10:47  | 22   | EMS  | 00:01:14   | 00:07:20       |
| 19002 | 40.1787   | -75.20511  | SUBJECT IN PAIN     | UPPER DUBLIN      | 2015-12-20   | 09:42:01     | 2015-12-20 | 09:39:03  | 9    | EMS  | 00:02:58   | 00:05:35       |
| 19446 | 40.244503 | -75.28082  | UNRESPONSIVE SUB... | LANSDALE          | 2015-12-22   | 10:47:00     | 2015-12-22 | 10:41:45  | 10   | EMS  | 00:05:15   | 00:05:54       |
| 19422 | 40.1848   | -75.28688  | CARDIAC EMERGENCY   | WHITPAIN          | 2015-12-24   | 09:57:00     | 2015-12-24 | 09:55:46  | 9    | EMS  | 00:01:14   | 00:04:39       |
| 19401 | 40.11381  | -75.34512  | ABDOMINAL PAINS     | NORRISTOWN        | 2015-12-25   | 16:52:00     | 2015-12-25 | 16:50:23  | 16   | EMS  | 00:01:37   | 00:06:15       |
| 19464 | 40.245007 | -75.59305  | ABDOMINAL PAINS     | LOWER POTTS GROVE | 2015-12-27   | 15:17:01     | 2015-12-27 | 15:12:43  | 15   | EMS  | 00:04:18   | 00:07:20       |
| 18964 | 40.301308 | -75.33012  | RESPIRATORY EMER... | FRANCONIA         | 2015-12-27   | 18:32:01     | 2015-12-27 | 18:27:13  | 18   | EMS  | 00:04:48   | 00:04:55       |
| 19066 | 40.002834 | -75.246    | UNCONSCIOUS SUBJECT | LOWER MERION      | 2015-12-27   | 20:52:01     | 2015-12-27 | 20:48:07  | 20   | EMS  | 00:03:54   | 00:07:04       |
| 19440 | 40.2808   | -75.28075  | RESPIRATORY EMER... | HATFIELD TOWNSHIP | 2015-12-28   | 15:37:00     | 2015-12-28 | 15:33:31  | 15   | EMS  | 00:03:29   | 00:03:44       |

only showing top 20 rows

# GOLD Flat Table

```
# create gold database
spark.sql(
  """
  CREATE DATABASE IF NOT EXISTS gold_911 LOCATION 'hdfs://hdfs-nn:9000/AVI/gold/gold_911.db/'
  """
)
```

DataFrame[]

```
# create sales_per_country table in gold
spark.sql(
  """
  DROP TABLE IF EXISTS gold_911.EmergencyCallsGold
  """
)
```

DataFrame[]

```

spark.sql(
    """
    CREATE EXTERNAL TABLE gold_911.EmergencyCallsGold (
        zip INT,
        lat FLOAT,
        lng FLOAT,
        town VARCHAR(50),
        call_date VARCHAR(50),
        hour INT,
        type VARCHAR(50),
        total_type INT,
        reply_time VARCHAR(50),
        reply_time_avg VARCHAR(50)

    )
    USING DELTA
    LOCATION 'hdfs://hdfs-nn:9000/AVI/gold/gold_911.db/EmergencyCallsGold/'
    """
)

```

DataFrame[]

```

spark.sql(
    """
    SELECT *
    FROM gold_911.EmergencyCallsGold
    """
).show()

```

```

+---+---+---+---+---+---+---+---+---+---+---+---+
|zip|lat|lng|town|call_date|hour|type|total_type|reply_time|reply_time_avg|
+---+---+---+---+---+---+---+---+---+---+---+---+
+---+---+---+---+---+---+---+---+---+---+---+---+

```

```
from pyspark.sql.functions import substring, avg, sum
```

```
# read data from the silver tables
```

```
flat_911_df = spark.table("silver_911.EmergencyCalls")
```

```
from pyspark.sql.functions import count
```

```
flat_911_df = flat_911_df \
```

```
    .groupBy("zip", "lat", "lng", "town", "call_date", "hour", "type", "reply_time_Avg") \
```

```
    .agg(
        count(flat_911_df.type).alias("total_type"),
    )
```

```
flat_911_df.show()
```

| zip   | lat       | lng        | town            | call_date  | hour | type | reply_time_Avg | total_type |
|-------|-----------|------------|-----------------|------------|------|------|----------------|------------|
| 18964 | 40.301308 | -75.33012  | FRANCONIA       | 2015-12-27 | 18   | EMS  | 00:04:55       | 1          |
| 19010 | 40.036663 | -75.31764  | LOWER MERION    | 2016-01-06 | 5    | EMS  | 00:08:08       | 1          |
| 19072 | 40.031464 | -75.25171  | LOWER MERION    | 2015-12-14 | 16   | EMS  | 00:05:40       | 1          |
| 19406 | 40.071648 | -75.34612  | UPPER MERION    | 2016-02-03 | 22   | EMS  | 00:05:32       | 1          |
| 19446 | 40.247074 | -75.305435 | TOWAMENCIN      | 2015-12-23 | 5    | EMS  | 00:05:54       | 1          |
| 19401 | 40.1287   | -75.339294 | NORRISTOWN      | 2015-12-13 | 8    | EMS  | 00:06:15       | 1          |
| 19462 | 40.115406 | -75.29713  | PLYMOUTH        | 2015-12-13 | 22   | EMS  | 00:06:34       | 1          |
| 19002 | 40.18643  | -75.19256  | HORSHAM         | 2016-02-03 | 12   | EMS  | 00:05:35       | 1          |
| 19473 | 40.25137  | -75.46571  | SCHWENKSVILLE   | 2015-12-11 | 13   | EMS  | 00:08:40       | 1          |
| 19401 | 40.11896  | -75.35136  | NORRISTOWN      | 2016-02-25 | 7    | EMS  | 00:06:15       | 1          |
| 19044 | 40.173264 | -75.15084  | HORSHAM         | 2016-04-01 | 10   | EMS  | 00:07:21       | 1          |
| 19462 | 40.114746 | -75.285446 | PLYMOUTH        | 2016-02-12 | 21   | EMS  | 00:06:34       | 1          |
| 19446 | 40.245674 | -75.27966  | LANSDALE        | 2016-02-18 | 23   | EMS  | 00:05:54       | 1          |
| 19038 | 40.102257 | -75.202805 | SPRINGFIELD     | 2016-03-30 | 10   | EMS  | 00:06:57       | 1          |
| 19401 | 40.119858 | -75.34049  | NORRISTOWN      | 2016-02-09 | 0    | EMS  | 00:06:15       | 1          |
| 19460 | 40.11316  | -75.51543  | CHESTER COUNTY  | 2016-03-25 | 9    | EMS  | 00:06:45       | 1          |
| 19438 | 40.278755 | -75.3865   | LOWER SALFORD   | 2016-03-21 | 18   | EMS  | 00:09:24       | 1          |
| 19492 | 40.300293 | -75.52594  | UPPER FREDERICK | 2016-03-08 | 10   | EMS  | 00:03:22       | 1          |
| 19446 | 40.238827 | -75.2896   | LANSDALE        | 2016-04-18 | 12   | EMS  | 00:05:54       | 1          |
| 19504 | 40.345352 | -75.57539  | DOUGLASS        | 2016-04-09 | 12   | EMS  | 00:03:36       | 1          |

only showing top 20 rows



```
flat_911_df = flat_911_df.withColumn("total_type", flat_911_df["total_type"].cast("integer"))
```

```
flat_911_df.printSchema()
```

```
root
|-- zip: integer (nullable = true)
|-- lat: float (nullable = true)
|-- lng: float (nullable = true)
|-- town: string (nullable = true)
|-- call_date: string (nullable = true)
|-- hour: integer (nullable = true)
|-- type: string (nullable = true)
|-- reply_time_Avg: string (nullable = true)
|-- total_type: integer (nullable = false)
```

```
flat_911_df.show()
```

| zip   | lat       | lng        | town            | call_date  | hour | type | reply_time_Avg | total_type |
|-------|-----------|------------|-----------------|------------|------|------|----------------|------------|
| 18964 | 40.301308 | -75.33012  | FRANCONIA       | 2015-12-27 | 18   | EMS  | 00:04:55       | 1          |
| 19010 | 40.036663 | -75.31764  | LOWER MERION    | 2016-01-06 | 5    | EMS  | 00:08:08       | 1          |
| 19072 | 40.031464 | -75.25171  | LOWER MERION    | 2015-12-14 | 16   | EMS  | 00:05:40       | 1          |
| 19406 | 40.071648 | -75.34612  | UPPER MERION    | 2016-02-03 | 22   | EMS  | 00:05:32       | 1          |
| 19446 | 40.247074 | -75.305435 | TOWAMENCIN      | 2015-12-23 | 5    | EMS  | 00:05:54       | 1          |
| 19401 | 40.1287   | -75.339294 | NORRISTOWN      | 2015-12-13 | 8    | EMS  | 00:06:15       | 1          |
| 19462 | 40.115406 | -75.29713  | PLYMOUTH        | 2015-12-13 | 22   | EMS  | 00:06:34       | 1          |
| 19002 | 40.18643  | -75.19256  | HORSHAM         | 2016-02-03 | 12   | EMS  | 00:05:35       | 1          |
| 19473 | 40.25137  | -75.46571  | SCHWENKSVILLE   | 2015-12-11 | 13   | EMS  | 00:08:40       | 1          |
| 19401 | 40.11896  | -75.35136  | NORRISTOWN      | 2016-02-25 | 7    | EMS  | 00:06:15       | 1          |
| 19044 | 40.173264 | -75.15084  | HORSHAM         | 2016-04-01 | 10   | EMS  | 00:07:21       | 1          |
| 19462 | 40.114746 | -75.285446 | PLYMOUTH        | 2016-02-12 | 21   | EMS  | 00:06:34       | 1          |
| 19446 | 40.245674 | -75.27966  | LANSDALE        | 2016-02-18 | 23   | EMS  | 00:05:54       | 1          |
| 19038 | 40.102257 | -75.202805 | SPRINGFIELD     | 2016-03-30 | 10   | EMS  | 00:06:57       | 1          |
| 19401 | 40.119858 | -75.34049  | NORRISTOWN      | 2016-02-09 | 0    | EMS  | 00:06:15       | 1          |
| 19460 | 40.11316  | -75.51543  | CHESTER COUNTY  | 2016-03-25 | 9    | EMS  | 00:06:45       | 1          |
| 19438 | 40.278755 | -75.3865   | LOWER SALFORD   | 2016-03-21 | 18   | EMS  | 00:09:24       | 1          |
| 19492 | 40.300293 | -75.52594  | UPPER FREDERICK | 2016-03-08 | 10   | EMS  | 00:03:22       | 1          |
| 19446 | 40.238827 | -75.2896   | LANSDALE        | 2016-04-18 | 12   | EMS  | 00:05:54       | 1          |
| 19504 | 40.345352 | -75.57539  | DOUGLASS        | 2016-04-09 | 12   | EMS  | 00:03:36       | 1          |

```
# write to delta table
flat_911_df \
  .write \
  .format("delta") \
  .mode("overwrite") \
  .save("hdfs://hdfs-nn:9000/AVI/gold/gold_911.db/EmergencyCallsGold/")

# check the results in the table
spark.table("gold_911.EmergencyCallsGold").show()
spark.table("gold_911.EmergencyCallsGold").count()
```

| zip   | lat       | lng        | town             | call_date  | hour | type | total_type | reply_time | reply_time_avg |
|-------|-----------|------------|------------------|------------|------|------|------------|------------|----------------|
| 19464 | 40.251106 | -75.648445 | POTTSTOWN        | 2016-01-21 | 16   | EMS  | 1          | null       | 00:07:20       |
| 18969 | 40.327793 | -75.346176 | FRANCONIA        | 2015-12-29 | 12   | EMS  | 1          | null       | 00:08:01       |
| 19040 | 40.176487 | -75.09617  | UPPER MORELAND   | 2016-01-15 | 13   | EMS  | 1          | null       | 00:06:34       |
| 19475 | 40.19193  | -75.56734  | CHESTER COUNTY   | 2016-01-26 | 14   | EMS  | 1          | null       | 00:03:33       |
| 19406 | 40.091286 | -75.37321  | UPPER MERION     | 2015-12-13 | 17   | EMS  | 1          | null       | 00:05:32       |
| 19401 | 40.138706 | -75.31553  | EAST NORRITON    | 2015-12-12 | 11   | EMS  | 1          | null       | 00:06:15       |
| 19002 | 40.176403 | -75.22503  | LOWER GWYNEDD    | 2016-01-05 | 9    | EMS  | 1          | null       | 00:05:35       |
| 19403 | 40.133038 | -75.40846  | LOWER PROVIDENCE | 2015-12-21 | 19   | EMS  | 1          | null       | 00:06:16       |
| 19446 | 40.241055 | -75.26888  | LANSDALE         | 2016-01-31 | 11   | EMS  | 1          | null       | 00:05:54       |
| 19428 | 40.07283  | -75.30588  | CONSHOHOCKEN     | 2016-01-15 | 19   | EMS  | 1          | null       | 00:03:48       |
| 19006 | 40.157177 | -75.07183  | UPPER MORELAND   | 2015-12-15 | 9    | EMS  | 1          | null       | 00:06:19       |
| 19010 | 40.041313 | -75.3054   | LOWER MERION     | 2016-02-03 | 14   | EMS  | 1          | null       | 00:08:08       |
| 19096 | 39.99393  | -75.28489  | LOWER MERION     | 2016-02-16 | 12   | EMS  | 1          | null       | 00:03:43       |
| 19038 | 40.116985 | -75.16949  | UPPER DUBLIN     | 2016-02-10 | 0    | EMS  | 1          | null       | 00:06:57       |
| 19464 | 40.24388  | -75.61619  | POTTSTOWN        | 2016-02-19 | 12   | EMS  | 1          | null       | 00:07:20       |
| 19438 | 40.27112  | -75.35801  | LOWER SALFORD    | 2016-03-24 | 9    | EMS  | 1          | null       | 00:09:24       |
| 19006 | 40.12289  | -75.06415  | LOWER MORELAND   | 2016-03-21 | 4    | EMS  | 1          | null       | 00:06:19       |
| 18936 | 40.2316   | -75.21866  | MONTGOMERY       | 2016-03-04 | 10   | EMS  | 1          | null       | 00:03:41       |
| 19464 | 40.24291  | -75.64474  | POTTSTOWN        | 2016-02-09 | 13   | EMS  | 1          | null       | 00:07:20       |
| 19027 | 40.077957 | -75.10125  | ABINGTON         | 2016-04-11 | 10   | EMS  | 1          | null       | 00:07:42       |

only showing top 20 rows

A seguir apresenta se o código utilizado para passar da fase gold para um ficheiro delta para numa fase posterior poder passar todo o dataset já tratado para o tableau:

```
pip install delta-spark
```

```
Requirement already satisfied: delta-spark in /opt/conda/lib/python3.10/site-packages (2.1.0)
Requirement already satisfied: pyspark<3.4.0,>=3.3.0 in /usr/local/spark-3.3.0-bin-hadoop3/python (from delta-spark) (3.3.0)
Requirement already satisfied: importlib-metadata>=1.0.0 in /opt/conda/lib/python3.10/site-packages (from delta-spark) (4.11.4)
Requirement already satisfied: zipp>=0.5 in /opt/conda/lib/python3.10/site-packages (from importlib-metadata>=1.0.0->delta-spark) (3.9.0)
Requirement already satisfied: py4j==0.10.9.5 in /opt/conda/lib/python3.10/site-packages (from pyspark<3.4.0,>=3.3.0->delta-spark) (0.10.9.5)
Note: you may need to restart the kernel to use updated packages.
```

```
from pyspark.sql import SparkSession
from pyspark.sql import Row
from delta import *

# warehouse_location points to the default location for managed databases and tables
warehouse_location = 'hdfs://hdfs-nn:9000/AVI'

builder = SparkSession \
    .builder \
    .appName("Python Spark SQL Hive integration example") \
    .config("spark.sql.warehouse.dir", warehouse_location) \
    .config("hive.metastore.uris", "thrift://hive-metastore:9083") \
    .config("spark.sql.extensions", "io.delta.sql.DeltaSparkSessionExtension") \
    .config("spark.sql.catalog.spark_catalog", "org.apache.spark.sql.delta.catalog.DeltaCatalog") \
    .config("spark.jars.packages", "io.delta:delta-core_2.12:1.0.0") \
    .enableHiveSupport() \

spark = configure_spark_with_delta_pip(builder).getOrCreate()
```

```
spark.sql("""
GENERATE symlink_format_manifest FOR TABLE delta.`hdfs://hdfs-nn:9000/AVI/gold/gold_911.db/EmergencyCallsGold/`
""").show()
```

```
++
||
++
++
```

```

spark.sql("""
DROP TABLE IF EXISTS gold_911.EmergencyCallsGold_presto
""").show()

spark.sql("""
CREATE EXTERNAL TABLE IF NOT EXISTS gold_911.EmergencyCallsGold_presto (
    zip INT,
    lat FLOAT,
    lng FLOAT,
    town VARCHAR(50),
    call_date VARCHAR(50),
    hour INT,
    type VARCHAR(50),
    total_type INT,
    reply_time VARCHAR(50),
    reply_time_avg VARCHAR(50)
)
ROW FORMAT SERDE 'org.apache.hadoop.hive.ql.io.parquet.serde.ParquetHiveSerDe'
STORED AS INPUTFORMAT 'org.apache.hadoop.hive.ql.io.SymlinkTextInputFormat'
OUTPUTFORMAT 'org.apache.hadoop.hive.ql.io.HiveIgnoreKeyTextOutputFormat'
LOCATION 'hdfs://hdfs-nn:9000/AVI/gold/gold_911.db/EmergencyCallsGold/_symlink_format_manifest/'
""").show()

```

```

++
||
++
++

++
||
++
++

```

```

spark.sql("DROP TABLE IF EXISTS gold_911.EmergencyCallsGold_conformmed_presto").show()

```